

1 INTRODUÇÃO

Inteligência Artificial aplicada a análise de Eletrocardiograma

Augusto Felipe Maggioni ¹
Marcelo Trindade Rebonatto ²

Resumo: A Inteligência Artificial oferece mecanismos e automatização para previsões no campo da saúde, beneficiando a população e a qualidade de vida de cada indivíduo que está sendo assistida por ela. Em conjunto, os dispositivos Internet of Things são aliados fundamentais para esse sistema, uma vez que são primordiais para a extração e monitoramento de dados. Entretanto, surge o desafio de conciliar os algoritmos com os aparelhos inteligentes a fim de detectar e distinguir arritmias, problemas cardíacos com mais causa de mortes no mundo. O objetivo deste trabalho é construir um modelo de previsão de arritmias cardíacas, em específico Fibrilação Arterial e Bradicardia Sinusal a partir de dados coletados do aparelho multiclinico MP-IoT. Foi realizado o treinamento de uma Inteligência Artificial aliando as técnicas de *Bidirectional Long Short-Term Memory*, *Convolutional Neural Network* e Redes Neurais Densas. Os dados necessários para esse treinamento foram obtidos a partir da plataforma Physionet, totalizando 66.989 dados com arritmias e normais. Os resultados obtidos são promissores para previsões de arritmias com o aparelho MP-IoT, haja vista as métricas de avaliações de 96.91%, 96.91%, 96.90%, 96.90% e 98.45% de acurácia, precisão, *Recall*, *F1-score* e especificidade.

Palavras-chave: Arritmias. Internet das Coisas. Bi-LSTM. CNN. MP-IoT.

Abstract: *Artificial Intelligence offers mechanisms and automation for predictions in the field of health, benefiting the population and the quality of life of each individual who is being assisted by it. Together, Internet of Things devices are fundamental allies for this system, since they are essential for data extraction and monitoring. However, the challenge arises of reconciling algorithms with smart devices in order to detect and distinguish arrhythmias, cardiac problems with the highest cause of death in the world. The objective of this work is to build a prediction model of cardiac arrhythmias, specifically Arterial Fibrillation and Sinus Bradycardia from data collected from the MP-IoT multiclinical device. An Artificial Intelligence was trained combining the techniques of Bidirectional Long Short-Term Memory, Convolutional Neural Network and Dense Neural Networks. The necessary data for this training were obtained from the Physionet platform, totaling 66,989 data with arrhythmias and normal. The results obtained are promising for predicting arrhythmias with the MP-IoT device, given the evaluation metrics of 96.91%, 96.91%, 96.90%, 96.90% and 98.45% of accuracy, precision, Recall, F1-score and specificity.*

Keywords: Arrhythmias. Internet of Things. Bi-LSTM. CNN. MP-IoT.

1 INTRODUÇÃO

As tecnologias computacionais viabilizaram ao mundo uma revolução de conhecimentos e descobertas na área médica em que sistemas inteligentes são construídos para acelerar o reconhecimento de doenças e monitorar a saúde [1]. Aliado a isso, é possível reduzir custos de consultas presenciais ao médico e crescimento da consciência de saúde pessoal[1, 2]. Essa atividade está associada ao progresso dos dispositivos *Internet of Things (IoT)*, uma vez que são capazes de medir, diagnosticar, monitorar e injetar pequenas dosagens precisas de medicamentos no corpo [2]. À medida que esses aparelhos avançam, também são necessários softwares e ferramentas que processam os dados coletados de maneira eficiente.

¹Graduando em Ciência da Computação, UPF, Campus 1 - BR 285 - Passo Fundo (RS) - Brasil
{176387@upf.br}

²Professor Orientador: Marcelo Trindade Rebonatto
{rebonatto@upf.br}

O eletrocardiograma (ECG) registra a atividade elétrica do coração e é parte fundamental da avaliação cardiovascular, sendo essencial para a investigação de arritmias cardíacas. Os eletrodos colocados na superfície do corpo captam as variações das correntes elétricas geradas pela polarização e despolarização das células musculares do coração [3]. A familiaridade com a ampla variedade de padrões observados nos eletrocardiogramas de indivíduos normais e a compreensão dos efeitos de distúrbios não cardíacos no traçado do plano quadriculado são pré-requisitos para uma interpretação precisa [3].

No histórico brasileiro, há um aumento significativo de causas de mortes por doenças cardiovasculares desde a década de 1960. Em contrapartida, o sistema público do país ajudou a diminuir essa problemática, mas que continua de grande relevância para continuar a preservar vidas [4]. Dados mais recentes de doenças cardiovasculares do Brasil, na pesquisa de Brant et al. [5], indicam que os riscos cardíacos são a maior parte de mortalidades para doenças cardiovasculares, principalmente por hábitos inadequados, exigindo investimentos e novas políticas de saúde pública.

A Fibrilação Arterial (AFIB) no Estados Unidos, na China e na União Europeia são fatores de alerta devido o crescente diagnóstico que vem aumentando ao passar dos anos além de estimativas para o tempo futuro [6]. Ademais, a COVID-19 tem forte participação no início de problemas cardíacos, levando a hipótese de ocorrência de lesão miocárdica, cardiomiopatia de estresse e choque cardiogênico, observado no estudo de Oliveira et al. [7]. Esses problemas estão ligados a arritmias cardíacas, haja vista que danos causados no músculo ou aos nervos podem alterar a atividade elétrica do coração e induzir uma alteração correspondente na forma dos ECGs [6].

O dispositivo utilizado neste trabalho é o aparelho Multiclinico MP-IoT [8]. Nele, é possível coletar informações de oximetria, pressão arterial, temperatura, batimentos cardíacos e ECG. Para a coleta de sinais do ECG, é composto por três eletrodos que são posicionados nas posições aVR, aVL e aVF (Figura 2). O início da coleta das amostras do ECG se dá pelo usuário, seja pelo aplicativo, seja pelo próprio aparelho. Os dados são enviados via *Bluetooth* para o *smartphone* e armazenados no aplicativo e no servidor.

O objetivo deste trabalho consiste em detectar e distinguir as arritmias AFIB, *Sinus Bradycardia* (SB) e padrão cardíaco normal a partir de sinais de ECGs da derivação I. Para isso, duas bases públicas (Physionet [9]) de sinais de ECGs foram processadas. O treinamento da Inteligência Artificial (IA) proposto consistiu em um modelo híbrido aliando as técnicas de *Convolutional Neural Network* (CNN) para extração de características, *Bidirectional long short-term memory* (Bi-LSTM) a fim de memória a longo prazo e redes densas conectadas ao fim da rede para gerar a saída de probabilidades de cada classe. Diversos processos são realizados ao longo do trabalho para chegar a uma IA capaz de detectar arritmias. Busca-se detecções mais eficientes que a média de acurácia e precisão de médicos [10, 11], relógios inteligentes e através de *smartphones* [12, 13].

O restante do texto está dividido em cinco seções. A segunda seção aborda os modelos de IA, as métricas de avaliações e trabalhos relacionados, compondo a revisão de literatura. Na terceira parte são descritos os processos realizados nas bases de dados iniciais para construção da base processada em que e a construção do modelo de IA. A quarta seção, detalha os resultados obtidos no treinamento e na validação em ambiente real. Por fim, na seção 5, as considerações finais e agradecimentos.

2 REVISÃO DE LITERATURA

2.1 Modelos de Inteligência Artificial

Diversos modelos de uso da IA podem ser encontrados na literatura, sendo alguns dos mais utilizados os algoritmos de Aprendizado de Máquina (*Machine Learning*) e Aprendizado Profundo (*Deep Learning*) [14]. A área de Aprendizado Profundo possui processamentos mais complexos, seja pelo conhecimento matemático, seja pela programação e hardware com alto poder computacional. Neste contexto, diversas técnicas são encontradas:

- ***Deep Learning*:** é um tipo de aprendizado que tem como principal finalidade agir de forma semelhante à mente humana. As redes neurais são as estruturas chaves para esse processo constituídas por camadas de entradas, camadas ocultas e uma ou mais camadas de saída. Entre essas camadas, são realizados cálculos a partir de pesos e funções de ativações. Para a rede se propagar, existem o *forward* (para frente) e *backpropagation* (para trás). Essa área da IA é muita ampla e fez a necessidade de criar diversos algoritmos para

cada campo de atuação. Dentre eles, Redes Neurais Recorrentes (RNN), *Long short-term memory* (LSTM), *Convolution Neural Network* (CNN), *Bidirectional long short-term memory* (BiLSTM) [15].

- **Recurrent Neural Networks (RNN):** As RNN formam uma família de redes neurais, especialmente para o processamento de dados sequenciais, como o LSTM e BiLSTM. A informação sequencial é preservada no estado oculto da rede recorrente, passando por muitas etapas de tempo à medida que ela avança a cada novo processamento [15, 16].
- **Long short-term memory (LSTM):** Os LSTMs são um tipo de RNN que aprendem e memorizam dependências de longo prazo, recuperando informações passadas por longos períodos. Possuem boa eficiência em previsões de séries temporais, reconhecimento de fala, desenvolvimento farmacêutico, entre outras aplicações [15, 16].
- **Convolution Neural Network (CNN):** São formadas por múltiplas camadas e sua aplicação é mais usada, por ter melhor resultado, em análise de imagens e vídeos. Dentre as camadas, a Convolução possui diversos tipos de filtros em que processam os dados até chegar na camada *ReLU*, função de ativação mais utilizada, permanecendo apenas valores calculados por ela. Em seguida, ocorre a camada de *Max Pooling*, responsável por classificar, agrupar e reduzir sua dimensão pela metade. Por fim, ao criar a camada totalmente conectada, a camada final é composta por neurônios que contêm os resultados de treinamento [15].
- **Bidirectional long short-term memory (Bi-LSTM):** Muito semelhante a LSTM, Bi-LSTM tem auxílio da Rede Neural Recorrente Bidirecional (Bi-RNN), em que há a possibilidade de lidar com duas informações no mesmo estado, tanto de frente (atual), quanto de trás (histórico). Assim, esse modelo faz com que o Bi-LSTM tenha a vantagem do LSTM com *feedback* para a próxima camada, além de da características de manipular dados com dependência de longo alcance [15, 17].
- **Multi-Head Attention:** O foco desta rede é permitir que o modelo dê atenção a diferentes partes no processo de raciocínio na memória de forma simultânea e de várias perspectivas. Essa rede utiliza as RNN e suas variantes como grande parte de sua rede de codificação e decodificação. Entretanto, sua principal característica se difere quando há dependências de longa distância em uma sequência [18].

Essas técnicas são amplamente utilizadas para processamentos de sinais, seja realizando por rede neural híbrida, nome utilizado quando se une/ conecta mais de um tipo de algoritmo para chegar ao final de uma rede, seja utilizando apenas uma técnica.

2.2 Eletrocardiograma

O eletrocardiograma (ECG) é parte fundamental da avaliação cardiovascular, sendo essencial para a investigação de arritmias cardíacas. Além disso, também é útil no diagnóstico de distúrbios cardíacos, como infarto do miocárdio [3]. A Figura 1 ilustra um ciclo de ECG completo a partir de suas posições e nomenclatura para cada ponto destacado.

A contração e o relaxamento do músculo cardíaco resultam da despolarização e repolarização das células miocárdicas. Essas alterações elétricas são registradas por meio de eletrodos colocados nos membros e na parede torácica e transcritas em papel quadriculado para produzir um ECG. Dependendo da posição dos eletrodos em que é colocado na superfície do corpo, produz derivações que devem ser analisadas e observadas em diferentes pontos de vista. Elas podem variar em 12 derivações: torácicas (V1 a V6) e membros (I, II, III, aVR, AVL e AVF) [3]. As derivações dos membros são conhecidas pelo triângulo de *Einthoven* que representa a projeção dos vetores dos eixos dos membros [20], como demonstrado na Figura 2, sendo VR lado direito e VL lado esquerdo do corpo.

Arritmias cardíacas são um distúrbio no ritmo do coração em que os batimentos podem ser rápidos, irregulares ou mais lento que o normal. Para o ritmo mais rápido, encontram-se a fibrilação atrial (AFIB) e *flutter* atrial em que a onda QRS pode ser mais larga que o normal, mostrando uma despolarização ventricular mais prolongada. Para as arritmias de ritmo mais lento, a bradicardia sinusal (SB), caracterizado quando o nó sinoatrial, também conhecido como marcapasso do coração, gera impulsos elétricos mais lento que o normal, resultando em uma frequência cardíaca abaixo do normal (entre 50, 60 a 100 bpm) [3, 21].

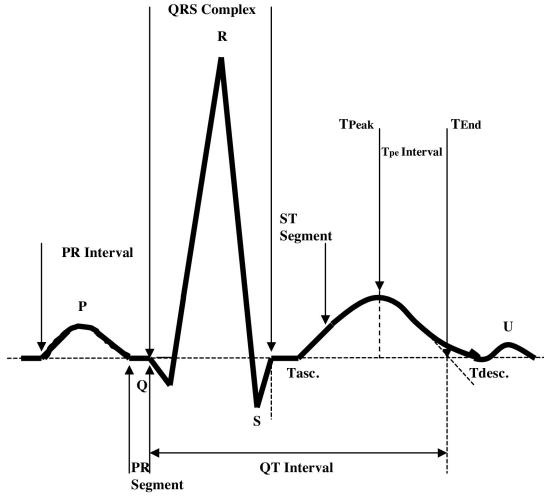


Figura 1: Exemplo de um ciclo completo de ECG e suas posições. Fonte [19].

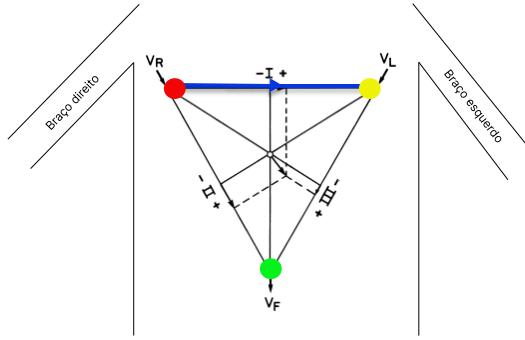


Figura 2: Triângulo de *Einthoven* mostrando a projeção de um vetor nos eixos de três derivações padrão dos membros com destaque para a derivação I. Fonte: Figura adaptada de [20].

O ECG de um batimento cardíaco normal em ritmo sinusal apresenta com três características: uma onda P apresentando a despolarização atrial, um complexo QRS denotando a despolarização ventricular e uma onda T representando a repolarização ventricular. A sequência característica normal do ciclo cardíaco é a onda P, o complexo QRS e a onda T com seções entre eles chamadas de segmentos [6].

2.3 Dispositivo MP-IoT

O MP-IoT [8] é um dispositivo multifuncional, conforme destacado na Figura 2.3, que realiza a coleta automática de oximetria, pressão arterial, temperatura, batimentos cardíacos e de ECG. Ele é capaz de capturar as informações e enviar os dados via *Bluetooth* para o aplicativo eProHealth [22]. No aplicativo é possível acompanhar o histórico de coleta e estatísticas do usuário. Além disso, possui um sistema onde é capaz autorizar um médico (ou profissional de saúde) a acessar e acompanhar o paciente.

Para a coleta do ECG, são disponibilizado três eletrodos que devem ser colocados em locais específicos de acordo com a Figura 2, cores verde (aVF), vermelho (aVR) e amarelo (aVL). A coleta das amostras de cada ECG pode ser realizada de diferentes derivações (I, II ou III), dependendo da posição de cada cor do eletrodo no corpo, variando as posições. Entretanto, este trabalho será realizado com a derivação I, pois o aparelho MP-IoT capta sinais de eletrocardiograma dessa derivação, conforme destacado na Figura 2.

A duração de cada coleta de ECG do aparelho contém aproximadamente 9,6 segundos do sinal do ECG. O sensor utilizado é baseado no circuito integrado 8232 [23] configurado para capturar amostras a 250 Hz de cada sinal e capacidade de armazenar 2400 valores. Além dessas características, o sinal contém apenas valores positivos



Figura 3: Dispositivo Multiclinico MP IoT

oriundos do conversor analógico digital.

2.4 Métricas de avaliação

As métricas de avaliação consistem em resultados estatísticos e matemáticos utilizados para avaliar o desempenho do algoritmo durante a fase de treinamento, de validação e de teste [24, 25]. Desta forma, as métricas ajudam na tomada de decisão de qual técnica ou conjunto de algoritmos escolher. Existem dois tipos de métricas para avaliação: a regressão e a classificação. A regressão é utilizada para medir o nível de perda da rede [25]. A classificação tem como finalidade avaliar a acurácia, precisão, *recall* e *F1-score* durante a classificação de arritmias [24].

2.4.1 Métricas para regressão

Antes de iniciar as métricas, é preciso conhecer as variáveis analisadas nas equações. O valor predito é representado por x_i , valor real por y_i e n o número de amostras.

- **Erro Quadrático Médio (MSE):** Essa métrica, uma das mais utilizadas para problemas de regressão, possui boa aplicação quando não se deve tolerar grandes erros, uma vez que eleva ao quadrado a diferença do valor real do predito. Seu valor mínimo é 0 e não possui valor máximo [26, 27].

$$MSE = \frac{1}{n} \sum_{i=1}^n (x_i - y_i)^2 \quad (1)$$

- **Raiz do erro quadrático médio (RMSE):** Muito semelhante ao MSE (Equação 1), o RMSE é sua raiz quadrada. Possui mais sensibilidade a erros e boa aplicabilidade em séries temporais [27, 28, 29].

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - y_i)^2} \quad (2)$$

- **Erro Absoluto Médio (MAE):** Essa métrica não penaliza tanto os *outliers* quanto a Equação 1 e Equação 2, pois não eleva seus valores ao quadrado. Dessa forma, MAE tem mais aplicabilidade em casos de previsões de tendências, e não em valores numéricos absolutos [27, 30, 31].

$$MAE = \frac{1}{n} \sum_{i=1}^n |x_i - y_i| \quad (3)$$

As métricas de regressões são essenciais para entender qual o desempenho do modelo em relação ao erro da rede. Assim, essas métricas são utilizadas para a fase de treinamento a fim de penalizar e verificar a cada época a sua perda e analisar o comportamento da rede.

2.4.2 Métricas para avaliações de desempenho de classificações ou previsões

Para o entendimento das métricas de classificação, é preciso entender alguns conceitos iniciais. Entre eles: Verdadeiro positivo (VP) em que amostras positivas classificadas corretamente; Verdadeiro Negativo (VN) em que amostras negativas são classificadas positivamente; Falso Positivo (FP) em que amostras incorretas são classificadas positivamente e Falso Negativo (FN) em que amostras positivas são classificadas negativamente [24]. A partir dessas classes, podemos extrair as métricas de Acurácia, Precisão, Recall e F1-score.

- **Acurácia:** Indica o total de acertos perante toda a amostra analisada. O valor varia de 0 a 1, quanto maior o valor, maior o índice de acertos. Entretanto, é uma métrica enganosa quando não há proporções de classes semelhantes. [24, 32, 33]

$$acuracia = \frac{VP + VN}{VP + VN + FP + FN} \quad (4)$$

- **Precisão:** Indica o total de acertos somente entre os dados que foram classificados como positivos. Isso significa que, ao total dos positivos, quantos dados realmente são classificados corretamente (positivos). Por exemplo, se a precisão tem resultado em 85%, isso indica que de 100 pessoas, 85 delas realmente foram classificadas corretamente. [24, 32]

$$precisao = \frac{VP}{VP + FP} \quad (5)$$

- **Recall (Revogação ou Sensibilidade):** Indica o total de acertos entre os dados que foram classificados como corretamente positivos sobre a amostra que foi classificado como correta, seja verdadeira ou falso. Isso significa que, ao total das classes positivas esperadas, quantos dados realmente são classificados corretamente. [24, 32]

$$recall = \frac{VP}{VP + FN} \quad (6)$$

- **F1-score:** Essa métrica leva em consideração a média harmônica da precisão e *recall* penalizando os valores extremos dessas duas métricas. Apresenta, ao final, uma melhor qualidade do modelo, variando de 0 a 1, sendo seu valor mais próximo de 1 um modelo mais assertivo. [24, 32, 33]

$$F1 = 2 \times \frac{precisao \times recall}{precisao + recall} \quad (7)$$

- **Especificidade:** É uma métrica que mede a capacidade do modelo em identificar corretamente os exemplos negativos, ou seja, a taxa de verdadeiros negativos (VN). É relevante quando a correta identificação dos casos negativos é importante. [33]

$$Especificidade = \frac{VN}{VN + FP} \quad (8)$$

- **Curva ROC-AUC:** A curva ROC é um gráfico que ilustra a taxa de verdadeiros positivos (VP) em relação a taxa de falsos positivos (FP), enquanto a AUC representa a área sob essa curva. Quanto mais próximo o valor da AUC estiver de 1, melhor será o desempenho do modelo, indicando uma boa capacidade de distinguir entre as classes positiva e negativa. Entretanto, um valor igual ou menor que 0,5 indica que o

modelo não possui capacidade de escolha. A equação *False Positive Rate* (FPR) representa a proporção de classes negativas que são incorretamente como positivas, enquanto a equação *True Positivo Rate* (TPR) ou *recall*, é a proporção da classe positiva classificadas corretamente. [34]

$$TPR = \frac{VP}{VP + FN} \quad (9)$$

$$FPR = \frac{FP}{FP + VN} \quad (10)$$

$$AUC = \int_0^1 TPR(FPR), d(FPR) \quad (11)$$

As métricas de classificações são essenciais para entender o desempenho do modelo em relação aos valores preditos. Conhecer e definir qual métrica utilizar perante a necessidade estabelecida avaliando os casos verdadeiros (positivos e negativos) e falsos (positivos e negativos), são fundamentais para o bom aproveitamento e a diminuição das chances de erros para a construção do modelo de IA.

2.5 Aplicação de IA em sinais de eletrocardiograma

Este artigo aborda conhecimentos e técnicas utilizadas na área de Internet das Coisas (*Internet of Things - IoT*), Inteligência Artificial (IA) e o processamento de sinais para predizer arritmias a partir de dados coletados por usuários domésticos com o dispositivo MP-IoT. Nesse viés, a medicina de precisão, esfera da saúde em que IoT e Inteligência Artificial trabalham em conjunto para proporcionar maior precisão em diagnósticos, doenças e facilitar o monitoramento constante do paciente, possui grande possibilidade de revolucionar o sistema de saúde [35]. Para essa finalidade, aliar esses dispositivos com a Inteligência Artificial em tempo real, é um dos maiores desafios para essa área [15].

A pesquisa de Zhou et al. [36] conclui que, ao usar *smartphones* auxiliado pelos seus sensores de movimento em uma caminhada em média de 6 minutos, é possível predizer a mortalidade da pessoa e indicativos de problemas cardíacos. Aliado a isso, técnicas de *Deep Learning* estão cada vez mais precisas e eficientes para reconhecer padrões e detectar riscos de mortalidade e morbidade [37]. Dessa forma, aliar aparelhos inteligentes no cotidiano das pessoas com um software capaz de processar e analisar os dados de maneira eficiente, tende a contribuir para o bem-estar individual e o sistema de saúde do país, podendo prevenir problemas mais sérios como Acidente Vascular Cerebral (AVC) e auxiliar no tratamento precoce de doenças cardíacas.

Diversos trabalhos utilizam técnicas de IA para prognóstico na área de saúde, entre eles, da cardiologia. O trabalho de ZHU et al.[17] utiliza *Bidirectional long short-term memory* (Bi-LSTM) e *Convolution Neural Network* (CNN) para reconhecer padrões eletrocardiológicos com 12 derivações e sem descrição de limitações de frequência. O artigo de Agarwal et al. [35] aplica algoritmos de *Deep Learning* para previsões de riscos cardiovasculares e auxiliar na interpretação de imagens médicas. O estudo de Chen et al. [38] empregou técnicas de LSTM e CNN para reconhecer mortalidades na base de dados MIMIC IV.

Já no trabalho de Fei et al.[17], realizado para uma análise de eletrocardiograma, a técnica Bi-LSTM é construída para predizer o risco de mortalidade, haja vista o duplo direcionamento que possui, podendo ser uma vantagem quanto ao algoritmo LSTM utilizado no estudo de Chen et al.[38]. A pesquisa da equipe de Soadoun et al. [39] utilizou dispositivos IoT junto a uma rede RNN para previsões de AFIB em coleta de ECG de 10 segundos.

No trabalho de Oliveira et al. [40], os autores extraíram diversos atributos do sinal do ECG para classificar o conjunto de quatro arritmias (SR, AFIB, GSVT e SB). Utilizou-se a combinação dos modelos *XGradient Boost*, *Random Forest* e *Gradient Boost* para a criação do modelo a fim de melhorar a performance de classificação.

O estudo Fausto et al. [41] conseguiu detectar a arritmia AFIB a partir de um modelo LSTM bidirecional com 60 a 80 épocas e 10 dobras de validação cruzada. Liu et al. [42] e Wang et al. [43] utilizaram em suas pesquisas redes convolucionais, CNNs, para detectar AFIB e chegaram a resultados semelhantes ao Fausto et al. [41].

mas não consideram cenários de medição e avaliação que empregam aparelhos de monitoramento pessoal portátil, como o aparelho MP-IoT

Nos trabalhos descritos não há informações explícitas de quantas derivações do ECG são usadas, exceto o trabalho de Zhu et al. [17], e o limite de frequência do sinal. Foram descritos sinais com frequência de amostragem de 500 Hz, variando o tempo de coleta para cada autor. Em resumo, a literatura dispõe de trabalhos correlatos com o objetivo de detectar arritmias a partir de sinais de ECG, mas não consideram cenários de medição e avaliação que empregam aparelhos de monitoramento pessoal portátil, como o aparelho MP-IoT. Dessa forma, o presente trabalho possui um conjunto características únicas, tais como faixa de frequência limitada de 0.05 a 30Hz, frequência de amostragem de 250Hz, uso de MP-IoT e de apenas uma derivação para predição de arritmias da normalidade.

3 MATERIAIS E MÉTODOS

Esta seção detalha as etapas e metodologias realizadas durante o trabalho, desde a preparação da base de dados, até a validação do modelo da IA em ambiente real. A preparação da base de dados contempla os filtros utilizados e as técnicas aplicadas nas amostras. Por último, são delineados os métodos e algoritmos de aprendizagem de máquina para a formalização da IA treinada. A Figura 4 ilustra o esquema inicial dos processos realizados apresentados nesta seção.

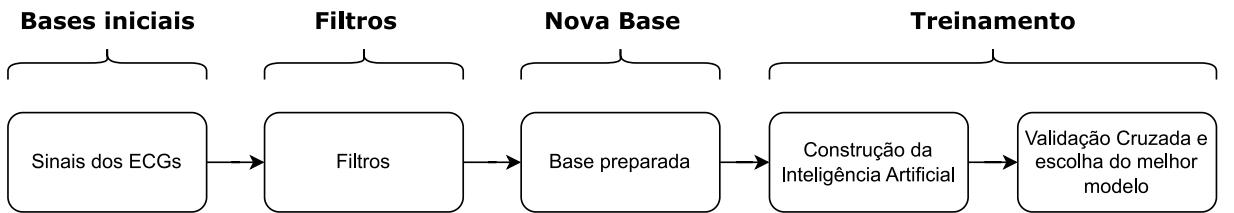


Figura 4: Visão geral dos processos realizados nesta seção, desde as bases iniciais até o treinamento e validação do modelo.

As subseções desta seção estão baseadas na seguinte ordem, como observado na Figura 4: Bases iniciais: coleta e processamentos (seção 3.1), filtros: rede elétrica; passa-banda de *Butterworth*, interpolação cúbica e suavização (seção 3.2); nova base: classificação e separação para treinamento, teste e validação (seção 3.3); construção da IA: modelos utilizados e sua ordem (seção 3.5) e, por fim, validação cruzada e a escolha do melhor modelo (seção 3.6).

3.1 Bases de dados e processamento

A base de dados deste trabalho foi criada a partir de duas bases de dados públicas [44] e [45] disponíveis a partir da *Physionet* [9]. Após a união das bases, os dados foram processados para chegar a base final com 44.217 registros classificados somente como arritmias e normal. Ambas as bases contêm 12 derivações, mas este trabalho considerou somente sinais da derivação I, de 500Hz em 10 segundos, dispondo de 5000 amostras de sinais para cada eletrocardiograma, sem valores repetidos. Dessa forma, como os sinais são de 500Hz, é preciso fazer a redução de frequência usando a interpolação cúbica (ver seção Filtros 3.2).

É importante enfatizar que todos os valores de sinais foram deslocados e transformados em positivos (*shift*). Isso significa que não haverá valores negativos na construção dessa nova base. Esse processo é necessário, pois as amostras dos sinais de saída do aparelho MP-IoT, conforme o *datasheet AD8232* [23] são filtrados apenas para valores positivos, ou seja, não há valores negativos que o aparelho retorna para a análise das amostra do sinal.

3.1.1 Base de eletrocardiograma para arritmias

O dataset “A large scale 12-lead electrocardiogram database for arrhythmia study“ [44] possui dados de 45.152 de eletrocardiogramas com classificações de arritmia, condução, hipertrofia e infarto. Sua base de dados é composta de arquivos no formato *WaveForm DataBase* (WFDB) que contém as informações e características de cada ECG. Dentre eles, o arquivo denominado cabeçalho (.hea), contém informações sobre frequência do eletro-

cardiograma, quantidade de amostras, voltagem (ddp), idade (#Age), sexo (#Sex), o diagnóstico do paciente de acordo com a codificação padrão da Classificação Internacional de Doenças (CID) (#Dx).

Nos arquivos brutos com a extensão .mat, possuem uma matriz de 12 colunas, sendo cada índice dessa matriz uma sequência de 5000 amostras que formam os sinais de cada derivação para 10 segundos em frequência de 500Hz. Para o trabalho em discussão, foi utilizado apenas o índice 0 dessa base que contém os sinais da derivação I de cada paciente. Entretanto, para deixar os valores dos sinais na mesma escala em que o aparelho MP-IoT tem como saída, foi necessário dividir cada um dos sinais por 10^3 , para ajustar os valores a escala de 0 a 0.05 mV.

Além disso, essa base possui o arquivo ConditionNames_SNOMED-CT.xlsx que contêm informações de anotação com configuração dos eletrodos, idade, sexo e código SNOMED CT. Dessa forma, é realizado o mapeamento entre os rótulos das letras originais e o código SNOMED CT. O Anexo A contém a Tabela A, onde as relações das variáveis são colocadas de maneira mais detalhada.

3.1.2 Base PTBXL

O dataset “PTB-XL, a large publicly available electrocardiography dataset“ [45] possui 21.837 dados classificados em normal, infarto, condução, hipertrofia e alterações da onda ST/T. Entretanto, também possuem outras possíveis alterações que não estão claras na documentação, mas que não foram utilizadas neste trabalho. Foram selecionadas apenas 6.094 sinais classificados como normais dos eletrocardiogramas: as que possuem o valor de 100 na variável *scp_codes* do arquivo ptbxl_database.csv.

A leitura dos arquivos é semelhante para a base anterior através do formato WFDB que contém as informações e características de cada ECG. Nos arquivos brutos com a extensão .dat, possuem 12 matrizes que formam uma sequência de 5000 amostra para cada derivação de 10 segundos em frequência de 500Hz. O arquivo ptbxl_database.csv contém metadados relevantes para cada ECG como id do paciente, idade, sexo, altura, peso, enfermeira, local, dispositivo, data de gravação e informações dos sinais entre outros. O arquivo *scp_statements.csv* armazena informações sobre o código e qual o diagnóstico cardíaco.

3.2 Filtros

Esta subseção aborda os filtros aplicados para a construção da base de dados a ser utilizada. Os filtros são necessários para remover interferências ou atenuar ruídos, preservando padrões e evitando ao máximo a perda de informação. Esta seção detalha e explica os processos realizados por cada filtro até chegar a base final para o treinamento da IA (Figura 5).

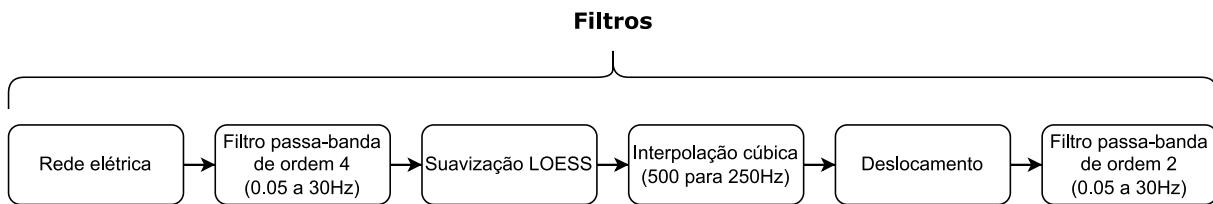


Figura 5: Processos de filtros realizados para a construção da base final.

A Figura 5 ilustra a ordem dos filtros realizados durante este trabalho. Ao total, observa-se os processos realizados para seis filtros, a partir da rede elétrica até o filtro passa banda de ordem 2. Depois dessa sequência de procedimentos realizados, então forma-se a base preparada que será necessária para o treinamento da IA.

3.2.1 Rede elétrica

O filtro de *Infinite Impulse Response* (IIR) notch é um tipo de filtro digital utilizado para atenuar frequências específicas de um sinal. Esse filtro é utilizado no processamento de sinais de ECG para remover interferências de frequências específicas, artefatos musculares e interferências de equipamentos médicos. De acordo com Ying-Wen et al. [46], esse filtro pode suprimir os ruídos da linha de energia para o processamento digital de sinais. Como os

dados são provenientes do país da República Popular da China, a rede elétrica padrão é de 50Hz.

De acordo com *American Heart Association (AHA)*, qualquer anomalia na sequência regular dos sinais elétricos dos batimentos cardíacos é considerada arritmia. Caso seja diagnosticado, o tratamento médico pode evitar problemas futuros. Assim, o filtro de rede elétrica se torna importante e adequado para atenuar possíveis frequências que possam interferir no diagnóstico e na predição da IA.

Apesar de Karri e Annavarapu [47] utilizarem Transformada Wavelet Discreta (DWT) para detecção de anomalias de diferentes tamanhos e frequências no sinal de ECG, principalmente para os complexos QRS, o filtro *notch* tem como característica apenas remover as interferências da rede elétrica, já que processos de passa banda ainda serão aplicados para reduzir a frequência além do que é captado pelo aparelho MP-IoT.

3.2.2 Filtro passa-banda de Butterworth

O filtro passa-banda é uma técnica que permite a remoção de frequências indesejadas e a preservação das informações relevantes em sinais de ECG. Esse tipo de filtro permite a passagem das frequências que estão dentro de uma faixa pré-definida, enquanto atenua as frequências que estão fora dessa faixa. Dessa forma, os filtros aplicados conforme proposto por Jagtap e Upplane [48] não oferecem risco para a perda de informações relevantes pelo processo, somente pelo índice de corte em que é aplicado.

A faixa de frequência a ser preservada varia de 0,05Hz a 30Hz, pois nessa faixa estão presentes as informações das amostras dos sinais do ECG. Dessa forma, o filtro do tipo *Finite Impulse Response (FIR)* é aplicado, visto que são filtros digitais com resposta de impulso finita, ou seja, não possuem retroalimentação e não sofrem modificação após um sinal já ter sido alterado, preservando ao máximo a característica e proporcionalidade da amostra do ECG.

O filtro passa-banda de *Butterworth* foi aplicado em duas ocasiões no processamento: a primeira, logo após a filtragem da rede elétrica com ordem 4; a segunda aplicação foi realizada na última etapa do processamento, com ordem 2. A ordem refere-se ao número de estágio do filtro que afeta a atenuação das frequências e a taxa de passa-banda [49], quanto maior seu valor, maior a filtragem. Em ambas, com filtro de 0,05Hz passa-alta e 30Hz para passa-baixa.

3.2.3 Suavização de LOESS

O filtro *Local Regression Scatterplot Smoothing (LOESS)* foi escolhido para suavizar os sinais. Esse filtro tem como função combinar técnicas de regressão polinomial local com uma janela de ponderação que dá mais pesos aos pontos próximos do ponto que está sendo estimado. Além disso, é útil para remover os ruídos de baixa frequência, sendo muito utilizado em processamento de sinais [50]. Segundo o trabalho realizado por Zheng [6], o autor utilizou esse filtro para classificação de arritmias para a mesma base utilizada neste trabalho [44].

O filtro foi aplicado depois do filtro passa-banda de *Butterworth* com o tamanho de janela definido em 10. Esse valor é pequeno para cada fração de cálculo a fim de não ocorrer tanta variação e preservar mais o sinal, haja vista que um valor mais alto pode levar a perda de informações importantes. O tamanho da janela significa o conjunto de quantas amostras será realizada a aplicação do filtro.

3.2.4 Interpolação Cúbica e deslocamento

A interpolação cúbica para sinais de ECG é uma técnica utilizada baseada na aproximação de polinômios cúbicos entre os pontos conhecidos permitindo a reconstrução do sinal com um aumento ou diminuição na frequência de amostragem. Dessa forma, é usada para estimar os valores desconhecidos entre os pontos conhecidos em um sinal de ECG. Para isso, os pontos conhecidos são ajustados por um polinômio de terceira ordem (cúbico) que passa por esses pontos e o valor desconhecido é estimado pelos seus coeficientes [51].

Interpolação cúbica é utilizada para diminuir a frequência de 500Hz, amostras padrão das duas bases selecionadas, para 250Hz, pois a frequência do aparelho MP-IoT é de 250Hz. Em [52] é descrito que realizar a interpolação linear de 500Hz para 250Hz fornece excelentes resultados. Entretanto, a interpolação cúbica pode produzir intervalos R-R mais precisos e, portanto, resulta em melhor correlação com sinais amostrados em frequências mais altas. Dessa forma, foi realizada a interpolação cúbica por se tratar de dados de uma dimensão e por se ajustar

melhor as curvaturas e mudanças na função que está sendo interpolada do que a interpolação linear. Aplicar esse filtro é necessário para que o treinamento seja adequado aos dados oferecidos do aparelho MP.

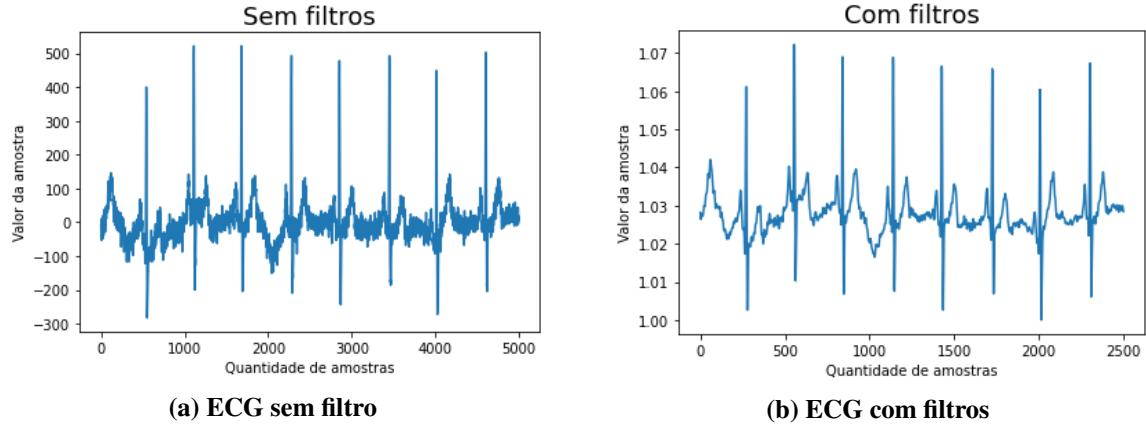
O deslocamento é um processo realizado para que os valores das amostras do sinal de ECG fiquem positivos, sem exceção, pois os valores que o aparelho MP-IoT [8] coleta são sempre acima de zero. Logo, para que haja proporcionalidade entre os dados, essa técnica é fundamental para que não ocorra perda de informações relevantes. O valor mínimo de cada amostra de sinal foi definido em 1. Dessa forma, como observa-se na Figura 6a o valor mínimo é próximo de -300, enquanto na Figura 6b, o valor mínimo é 1, mas sem perder a proporcionalidade.

3.2.5 Resultados produzidos com os filtros

A Figura 6 exibe as diferenças do eletrocardiograma antes e depois da aplicação dos filtros. Nesse exemplo, o ECG mostrado possui a anormalidade arritmica *Sinus Bradycardia* (SB) extraído da base de arritmias (Seção 3.1.1). Observa-se uma grande diferença em relação ao ECG original da Figura 6a em comparação com a Figura 6b. Essa diferença visual é explicada pelos processamentos de filtros, detalhados nesta subseção, além do ajuste de escala dos dados para a frequência e características de saídas do aparelho MP-IoT [8].

É possível analisar que o valor do sinal possui uma amplitude que varia de -300 a 500, além de possuir 5.000 amostras que representam a extração de 10 segundos a uma frequência de 500Hz [44]. Também é notável uma redução significativa de ruídos que formam o sinal, em que na Figura 6b, com filtros, possui uma linha mais definida e limpa, processo fundamental para que a rede possa detectar com clareza.

Figura 6: Comparação de ECG a partir da arritmia SB sem e com filtros aplicados



3.3 Base final

A base de dados final, usada para treinamento e testes neste trabalho, contém sinais de ECG com arritmias do tipo AFIB, *Sinus Irregularity* (SI) e SB, além de ECGs considerados normais. A Tabela 1 contém a quantidade inicial e final de amostras que cada classe possui. Conforme pode-se observar, as classes rotuladas estão desbalanceadas. Torna-se necessário equilibrar a quantidade de classes para um mesmo valor, ou com pouca diferença. Isso é fundamental para que a base de treinamento seja equilibrada entre as categorias, diminuindo as possibilidades de *overfitting* e melhorando as métricas de classificação da IA.

Classe	Sub-classe	Quantidade	
		Inicial	Final
Arritmia	AFIB	1780	1780
	SB	16559	1780
	SI	2550	1780
Normal	-	6103	1780

Tabela 1: Quantidade de amostras classificadas da base inicial e para treinamento

Ao analisar a Tabela 1 é possível constatar que a classe AFIB dispõe da menor quantidade de dados classificados, 1780 linhas. Preservando seu valor, foi escolhido de forma aleatória 1780 amostras das outras classes, finalizando a base com 7120 linhas de treinamento distribuídas igualmente entre as classes. Além disso, na base final há informações de sexo (0 para masculino e 1 para feminino), idade e de qual arquivo pertence esses dados.

A última etapa da preparação da base final antes do treinamento consistiu em normalizar os dados com *MinMaxScaler*³ no intervalo de 0 a 10 e dividir os dados para treinamento, teste e validação. Para o treinamento, foram utilizadas 80% (1424) amostras de cada classe foram separadas, totalizando em 5.696 linhas. Para validação, foi utilizado 20% (1424) dos dados, 356 para cada classe. Depois desse processo, a base foi dividida em 5 *folds* na validação cruzada.

3.4 Versões da Rede Híbrida Convolucional Bidirecional

Diversos testes foram realizados até chegar ao modelo com melhor desempenho, variando os hiperparâmetros, as arquiteturas, suas quantidades de neurônios e em diferentes posições nas redes híbridas. A evolução das versões da Rede Híbrida Convolucional Bidirecional (RHCN) ocorreu com cinco configurações diferentes:

- RHCN1: uso apenas de CNN;
- RHCN2: uso apenas de Bi-LSTM;
- RHCN3: uso de CNN e de Camadas densas;
- RHCN4: uso de CNN, somada a redes de *Attention* e Camadas densas;
- RHCN5: uso de CNN somada a Bi-LSTM e Camadas densas;

O RHCN1 foi treinado somente com camadas convolucionais, *Max Pooling* e com *dropout*. Para o modelo RHCN2 foi utilizadas apenas duas camadas Bi-LSTM com 256 e 128 neurônios em sequências. Para o RHCN3 foi utilizado camadas densas com 256, 128, 64 e 4 neurônios, respectivamente, iniciando com uma rede CNN com 256 neurônios. O RHCN4 utilizou o hibridismo de camadas convolucionais, de atenção e de redes densas em conjunto. A rede RHCN5 representada pela Figura 7 alcançou as maiores métricas de validação e testes, como observado na Tabela 2 e na Tabela 3. Todas as versões das redes RHCN foram construídas e que tiveram a mesma quantidade de camadas e neurônios do modelo final (RHCN5), variando as arquiteturas de aprendizagem.

Ao construir um modelo simples com CNN e Bi-LSTM, com poucos neurônios (16 e 32) e (32, 64), respectivamente, a rede fica instável e acaba não aprendendo. Além disso, com poucas camadas na rede o desempenho na validação dos dados ocorre o *overfitting*. Por outro lado, ao aumentar a quantidade de neurônios, por exemplo, 256 e 512 neurônios com duas ou mais camadas, seja para CNN, seja para Bi-LSTM, o tempo de processamento ficou elevado além de ocorrer *overfitting* com maior facilidade. Vale ressaltar que ao utilizar no mínimo duas camadas consecutivas Bi-LSTM na rede, a aprendizagem piora bastante, ficando em cerca de no máximo 40% na validação dos dados.

Observa-se que ao utilizar apenas camadas de CNN o desempenho fica em torno de 50 a 60% nas métricas de acurácia e precisão. Utilizando somente LSTM ou Bi-LSTM o modelo não conseguiu distinguir as classes, com métricas ficando em cerca de 20 a 35%. Quando adicionado camadas de atenção [18] no lugar do modelo Bi-LSTM, o desempenho fica semelhante ao utilizar Bi-LSTM, mas nas métricas de desempenho ocorre muita variação na aprendizagem. Quando adicionado no início da rede, o desempenho cai e o tempo aumenta, isso com duas cabeças. Com apenas uma cabeça, mas com 128 neurônios, ocorre *overfitting* resultando entre 70 a 80% nas métricas de precisão e acurácia.

O uso de *dropout* em cada camada CNN e Bi-LSTM ajudaram a aumentar as métricas de avaliações e diminuir o *overfitting*. Utilizar 5 ou 10 *folders* na validação cruzada não houve diferenças nos resultados. Entretanto, ao utilizar 5 *folders* a rede ficou mais estável durante o treinamento.

³<https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.MinMaxScaler.html>

3.5 Rede Híbrida Convolucional Bidirecional 5 (RHCB5)

A IA construída neste trabalho está baseada em uma rede híbrida com CNN, Bi-LSTM e camadas densas. A rede recebe como entrada um sinal de 2.400 amostras nas camadas CNN, seguida por outras três redes CNN de uma dimensão (Conv1D). Um dos hiperparâmetros a definir em cada camada convolucional são os *kernels*, configurado em 3 (valor padrão da rede). Sua função é aplicar filtros a partir de uma matriz de pesos de diferentes valores a fim de extrair variadas características em cada camada. Após ao término de cada camada convolucional é realizada o *MaxPooling*, processo em que um conjunto de neurônios é reduzido a fim de diminuir a dimensão de cada camada e preservar as características, além de ajudar a lidar com problemas de sobreajustes [53]. Posterior a essas aplicações, é aplicado o *dropout*. Essa técnica tem como finalidade forçar a rede a aprender características independentes a cada neurônio, esquecendo-os a partir de um subconjunto aleatório em cada camada, tornando a rede mais robusta e menos sensível a variação dos dados [53].

Depois das camadas CNN, a rede é constituída por apenas uma camada Bi-LSTM de 256 células que não sofreu modificações de parâmetros a partir da configuração padrão desta rede. Por fim, as três últimas camadas são compostas por redes densas, iniciando com 256 neurônios e *dropout* de 40%, seguido de outras duas camadas densas de 128 e 4 neurônios, sem *dropout*, respectivamente. Todas as camadas possuem função de ativação *ReLU*, exceto a última camada de saída que possui a ativação *softmax*. A função de ativação *ReLU* tem como propriedade retornar valores zeros para todos os valores negativos calculados, enquanto valores positivos ficam ativados na rede. Além disso, é computacionalmente eficiente, deixa a rede menos sensível e é capaz de ajudar com o *overfitting* [53]. Já a ativação *softmax* é utilizada para classificação multiclasse, necessário para retornar a probabilidade de saída para cada classe treinada (AFIB, SB, SI e normal) [54] (Figura 7).

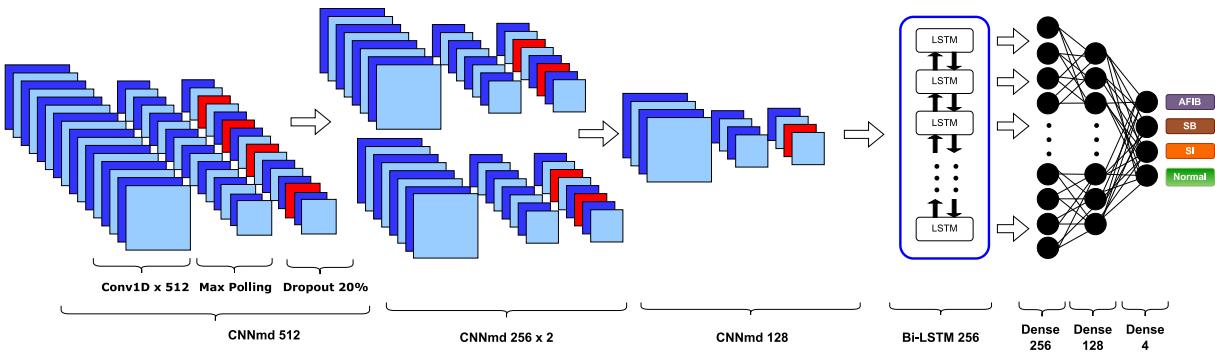


Figura 7: Representação da rede RHCB em sua 5a versão.

Na Figura 7 a rede RHCB pode ser visualizada, onde CNNmd512 significa uma rede CNN com 512 neurônios, CNNmd 256 x 2 duas redes CNN com 256 neurônios, CNNmd 128 uma rede CNN com 128 neurônios, todas com *Max Pooling* e *dropout* de 20%. Bi-LSTM 256 é uma rede Bi-LSTM com 256 neurônios e Dense 256, 128, 4 são as camadas densas com suas respectivas quantidades de neurônios. Entre a Dense 256 e 128, ocorre *dropout* de 40%.

O número de épocas e o número de lotes estão definidos em 60 [41] e 32, respectivamente. Após diversos testes com os mesmos dados, observou-se que essa configuração obteve as métricas maiores. A função de otimização definido foi *Adam* [55], função comumente utilizadas nos trabalhos relacionados [6, 36, 39, 41, 40, 43] por apresentarem melhores resultados. A função de perda é definida como *Categorical Crossentropy* [56] devido a rede ser de classificação e os rótulos estão no formato de vetores *one-hot*.

3.6 Validação cruzada e escolha do melhor modelo

Para realizar a validação cruzada foi definido o número de dobras em cinco (5). Isso significa que ao total serão cinco *folds*, sendo que necessariamente uma dobra fica para validação com 20% dos ECGs de treinamento, e os outros 80% ficam para treinarem entre si. Depois desse primeiro processo, outra dobra fica para teste e a última que estava para teste, agora se une aos dados de treinamento e assim sucessivamente [57]. Isso é importante para que o modelo consiga se adaptar e evitar *overfitting*. Entretanto, o tempo de processamento aumenta com esse

processo.

A escolha do melhor modelo se define no menor *loss* alcançado durante o treinamento das 300 iterações, 60 épocas com dobras de cinco. A etapa de definição do *checkpoint* é importante pelo fato de sempre armazenar e comparar ao final de cada época a métrica de perda da rede a fim. Assim, ao término de todo o treinamento, é possível carregar o modelo RHC2 que atingiu a melhor métrica de otimização para cada versão.

Além disso, a disponibilidade de recursos computacionais também pode influenciar a escolha do melhor modelo. Com as diferentes versões do modelo RHC2, todas foram executadas em compilação com GPU, *hardware* em que acelerou significativamente o tempo de processamento em comparação ao utilizar somente a CPU. Dessa forma, não ocorreram problemas de limitações de desempenho e tempo.

4 Resultados

Este capítulo apresenta os resultados obtidos durante o processo de treinamento e as diferentes versões de modelos utilizados para chegar ao modelo com a maior métrica de avaliação *recall*. Além disso, é apresentado processos de validação a partir de sinais gerados pelo simulador Fluke [58] e de dados coletados pelo dispositivo MP-IoT com a plataforma EproHealth.

4.1 Ambiente computacional de desenvolvimento e testes

Os experimentos foram realizados através da plataforma Google Colab com processador Intel(R) Xeon(R) de 2.00GHz, 12.7GB de memória RAM e GPU Tesla T4. Com alto poder de processamento, foi possível reduzir significativamente o tempo de processamento para placas gráficas convencionais de preço mais acessível.

O período de execução do treinamento, testes e validação ocorreram durante os meses de maio e junho de 2023. Esse tempo foi necessário para o planejamento, implementação e execução dos modelos a fim de construir uma IA com a menor taxa de erro a partir de um *checkpoint* que salva a cada época a rede com os pesos.

A linguagem de programação utilizada para o desenvolvimento deste trabalho foi *Python*. Para o treinamento do modelo RHC2 e validação das métricas foi utilizado o framework *TensorFlow*⁴. Para o processamento e manipulação de dados, foram utilizadas as bibliotecas *Pandas*⁵, *Numpy*⁶, *scikit-learn (Sklearn)*⁷, *WFDB*⁸, *scipy*⁹ e *Matplotlib*¹⁰ para visualização dos sinais de ECG.

4.2 Comparativo dos resultados obtidos

A fim de avaliar o desempenho de classificação do modelo, as métricas acurácia, precisão, *recall*, *F1-score*, especificidade e curva ROC-AUC foram avaliadas durante o treinamento. As métricas são baseadas nas medidas de verdadeiros positivos (VP), verdadeiro negativo (VN), falso positivo (FP) e falso negativo (FN) (subseção 2.4.2). A Tabela 2 contém os resultados comparativos dos cinco modelos submetidos ao treinamento e o tempo médio de cada época de treinamento para as 4 classes.

Ao analisar o resultado do modelo RHC2 com três ou quatro classes com o trabalho de Fausto et al. [41] e Soadoun [39] para detectar AFIB, com as técnicas de LSTM bidirecional e RNN, respectivamente, observa-se que a rede RHC2 não conseguiu atingir a mesma eficiência. A partir desse desempenho inferior, foi necessário buscar novas ideias e estudos de referências para esse trabalho. Dessa forma, os trabalhos de Liu et al. [42] e Wang et al. [43] usaram CNN para detectar AFIB. O modelo aumentou significativamente suas métricas de avaliações, como observado no modelo das versões RHC1 e RHC1 com três e quatro classes.

Apesar dos resultados ainda estarem com um desempenho inferior, mas apresentarem evolução, foi a partir

⁴<https://www.tensorflow.org>

⁵<https://pandas.pydata.org>

⁶<https://numpy.org>

⁷<https://scikit-learn.org>

⁸<https://physionet.org/content/wfdb>

⁹<https://www.scipy.org>

¹⁰<https://matplotlib.org>

Modelo	Acurácia	Precisão	Recall	F1-score	Especificidade	Tempo médio por época
RHCB 1	64.25%	64.93%	64.25%	63.60%	71.05%	22s
RHCB 2	25.07%	31.25%	25.07%	10.14%	0%	65s
RHCB 3	45.08%	44.60%	45.08%	44.76%	48.95%	7s
RHCB 4	79.84%	81.26%	79.84%	79.23%	92.34%	14s
RHCB 5	87.42%	87.31%	87.42%	87.33%	89.66%	20s

Tabela 2: Resultados com dados de testes das versões dos modelos RHCB com 4 classes.

pesquisa de Zhu et al. [17] que aliou as técnicas de CNN e Bi-LSTM para padrões de ECG de 12 derivações com métricas de cerca de 99% para classificação de AFIB, que a rede RHCB5, e sua derivação com camadas de atenção RHCB4, foram construídas. Apesar de seu trabalho não deixar claro quantas derivações foram utilizadas para o treinamento e se houve limitações de amplitudes e frequência da onda, utilizar essas duas técnicas de forma a criar uma rede híbrida trouxe os melhores resultados para o presente trabalho na rede RHCB5.

O modelo RHCB5 com três (3) classes obteve métricas de validação de 96.91% para acurácia, 96.91% para precisão, 98.45% para especificidade, 96.90% para *F1-score*, 96.90% para *Recall*. A rede teve o melhor desempenho nos testes de validação. Nota-se que o modelo obteve um bom aproveitamento diante das classes preditas, melhorando de forma significativa as métricas e a matriz de confusão em relação aos resultado do modelos com quatro classes apresentado na Tabela 2.

O modelo RHCB5 com quatro (4) classes obteve métricas de validação de 87.42% para acurácia, 87.31% para precisão, 89.66% para especificidade, 87.33% para *F1-score* e 87.42% para *Recall*. A rede teve um bom desempenho, mas não conseguindo evoluir além desse resultado, seja aumentando a quantidade de épocas, alterando o tamanho do lote ou a quantidade de *folders* da validação cruzada. Dessa forma, foi realizado testes com o RHCB para 3 classes (Tabela 3).

Modelo	Acurácia	Precisão	Recall	F1-score	Especificidade	Tempo médio por época
RHCB 1	92.13%	92.57%	92.13%	92.11%	92.17%	10s
RHCB 2	37.92%	38.30%	37.92%	36.55%	69.67%	46s
RHCB 3	56.83%	59.59%	56.83%	55.02%	77.17%	5s
RHCB 4	93.53%	63.69%	93.53%	93.51%	96.74%	11s
RHCB 5	96.91%	96.91%	96.90%	96.90%	98.45%	14s

Tabela 3: Resultados com dados de testes das versões dos modelos RHCB com 3 classes.

A matriz de confusão da Tabela 4 contém o desempenho da IA em cada classe para os dois modelos RHCB treinado a partir do *checkpoint* com o menor *loss* da validação cruzada de 5 *folders*.

Classes	Predição com 4 classes				TOTAL	Predição com 3 classes			TOTAL
	AFIB	SB	SI	NORMAL		AFIB	SB	NORMAL	
Verdade	AFIB	350	2	2	356	354	1	1	356
	SB	5	303	37	356	5	337	14	356
	SI	8	40	273	356	-	-	-	-
	NORMAL	2	18	17	356	4	8	344	356
TOTAL		365	363	329	367	363	346	359	

Tabela 4: Matriz de Confusão do modelo híbrido RHCB5 com 3 e 4 classes preditas de testes.

Fica perceptível que ao adicionar a classe SI ao modelo de classificação há uma redução de desempenho em cerca de 8%. Isso porque, na derivação I, a partir dos processos realizados nas amostras de cada sinal, não há diferenças significativas capazes de conseguir distinguir das classes SB e normal, seja pela limitação de frequência, seja pela característica do sinal.

Ao analisar o resultado do modelo RHCB5 com três classes com o trabalho de Fausto et al. [41] e Soaduon [39], que utilizaram as técnicas de LSTM bidireccional e RNN, respectivamente, para detectar AFIB, observa-se

que a rede RHC5 conseguiu um bom desempenho em relação ao estudo dos autores. Entretanto, é importante ressaltar que em ambos os trabalhos não ficam explícitos com quantas derivações do ECG foram utilizadas. Além disso, não houve limitação de amplitude (filtro passa-banda de 0.05 a 30Hz) e frequência da onda (interpolação cúbica para 250 Hz). Essas limitações das amostras de ECGs podem reduzir significativamente a quantidade de informações relevantes para as previsões de três ou quatro classes utilizando somente técnicas de Bi-LSTM e RNN.

Os trabalhos de Liu et al. [42] e Wang et al. [43] usaram CNN para detectar AFIB com métricas em cerca de 99%. A rede RHC5 apresentou desempenho equivalente a CNN de Liu [42], com uma taxa de 2 a 3% menor. Apesar do desempenho ser próximo, vale destacar que essa diferença pode existir, possivelmente, pela quantidade de classes a ser preditas (três), assim como, pela limitação de amplitude e frequência.

Já para a pesquisa de Zhu et al. [17] que aliou as técnicas de CNN e Bi-LSTM para padrões de ECG de 12 derivações conseguindo métricas de cerca de 99% para classificação de AFIB, a rede RHC5 também apresentou desempenho semelhante com a arquitetura similar. Apesar do resultado (99%) não ser igual, mas semelhante (96%), essa pequena diferença pode ser explicada, embora o autor não tenha deixado claro quantas derivações foram utilizadas para o treinamento e se houve limitações de amplitudes e frequência da onda, o presente trabalho apresenta limitações e características únicas, tais como limitações de amplitudes, frequências das amostras de ECG e a quantidade de derivações.

4.3 Testes com simulador e dados da plataforma EproHealth

O simulador utilizado foi o *Fluke ProSim 4 Vital Signs Simulator* [58]. Foram geradas amostras de sinais com arritmias do tipo AFIB, SB, Bloqueio Atrioventricular, Assistolia, Fibrilação Ventricular (Grossa, fina, 160 bpm e 200 bpm) e normais. A frequência de amostragem é de 250 Hz com 9.6 segundos de duração resultando em aproximadamente 2400 amostras para cada sinal. Não houve limitação de amplitude da onda, ruídos e demais possíveis irregularidades para cada sinal gerado. A Tabela 5 apresenta os eventos gerados pelo simulador e a previsão da rede RHC5 de 3 classes.

ID	Evento	Predição	AFIB (%)	SB (%)	Normal (%)
1	Fibrilação Atrial Fina	AFIB	99.99	0.00	0.00
2	Fibrilação Atrial Grossa	AFIB	99.97	0.00	0.03
3	Normal 210 BPM	AFIB	99.96	0.00	0.04
4	Normal 150 BPM	Normal	32.60	0.00	67.40
5	Normal 90 BPM	Normal	0.00	0.00	100.00
6	Normal 60 BPM	Normal	0.02	0.84	99.15
7	Normal 30 BPM	SB	0.23	99.54	0.23
8	Assistolia	SB	0.62	99.05	0.33
9	Bloqueio Atrioventricular (BAVT) - 3º grau	SB	7.07	89.76	3.17
10	Bloqueio Atrioventricular (BAVT)- 1º grau	AFIB	99.99	0.00	0.00
11	Fibrilação Ventricular Fina	AFIB	99.17	0.06	0.78
12	TV Paced 75 BPM	AFIB	99.96	0.01	0.03
13	Fibrilação Ventricular Grossa	AFIB	98.15	0.10	1.76
14	Taquicardia Ventricular 160BPM	AFIB	99.99	0.00	0.00
15	Taquicardia Ventricular 200 BPM	AFIB	99.59	0.01	0.04

Tabela 5: Relação entre os eventos gerados pelo simulador e a previsão do modelo RHC5 com 3 classes

Ao analisar os IDs 1, 2, 3, 4, 5, 6 e 7, considerando que o ID 3 (Normal 210 BPM) pode ser considerado uma arritmia do tipo AFIB (alto batimento cardíaco acima de 200 BPM), assim como o ID 7 (Normal 30 BPM) pode ser classificado como uma arritmia do tipo SB, abaixo de 60 BPM, a rede RHC5 obteve 100% de acertos.

Além disso, ao analisar os IDs 8, 9, 10, 11, 12, 13, 14 e 15, em que todos são anomalias cardíacas e sabendo que o modelo RHC5 foi treinado apenas com AFIB, SB e normal, diferente dos eventos cardíacos gerados pelo simulador, observa-se que todas as previsões foram classificadas para um dos tipos de arritmias treinadas (AFIB ou SB). Essa análise é importante, pois, mesmo quando o sinal simulado continha uma irregularidade cardíaca,

6 AGRADECIMENTOS

diferente da qual o modelo RHC5 foi treinado, a rede conseguiu identificar e prever como uma anormalidade em vez de considerá-la como normal. Essa descoberta ressalta a importância de o paciente buscar a opinião de um cardiologista.

Para testar a eficiência do modelo RHC5 com o ECG do aparelho MP-IoT [8] em coleta de ambiente real, foram coletadas 5 amostras de diferentes pessoas. A Tabela 6 exibe a relação de idade, sexo M para masculino e F para feminino, predição do modelo RHC5 e o histórico da pessoa em relação ao seu último exame realizado e diagnosticado por um cardiologista.

ID	Idade	Sexo	Histórico	Predição RHC5
1	23	M	Normal	Normal
2	32	M	Normal	Normal
3	18	F	Normal	Normal
4	56	F	Normal	Normal
5	86	F	Insuficiência cardíaca	AFIB

Tabela 6: Relação entre as predições da rede RHC5 a partir de dados coletados em ambiente real do aparelho MP-IoT

Na Tabela 6 observa-se que a rede, comparando ao histórico dos indivíduos e das suas predições, obteve um bom desempenho. Dessa forma, é importante ressaltar que poucos testes em ambientes reais foram realizados e torna-se necessário testar com mais pacientes para testar e verificar a eficiência das predições que a rede RHC5 faz em conjunto com os sinais coletados do aparelho MP-IoT. Além disso, a métrica de avaliação *recall*, tanto na base de teste de treinamento, do simulador e nas predições a partir dos dados coletados do aparelho MP-IoT, obteve porcentagens acima de 96%, indicando que o modelo está classificando corretamente os dados positivos dos quais são esperados que sejam classificados como positivos.

5 Considerações Finais

Neste trabalho, nosso objetivo foi desenvolver uma rede híbrida de IA utilizando técnicas de *Convolutional Neural Network (CNN)*, *Bidirectional Long Short-Term Memory (Bi-LSTM)* e redes densas para a detecção as arritmias AFIB, SB e diferenciá-las de um ECG normal. Ao longo desta pesquisa, buscou-se criar um modelo eficiente e preciso capaz de auxiliar na identificação precoce e no monitoramento dessas arritmias.

A partir dos resultados, constatou-se que a rede híbrida proposta alcançou um desempenho promissor na detecção das arritmias com todas as suas limitações. A detecção precoce de arritmias cardíacas é crucial para a prevenção de complicações e oportuna intervenção médica. Apesar dos promissórios, é preciso que pesquisas futuras explorem a aplicação de técnicas avançadas de interpretabilidade em redes neurais, como *saliency maps* e *grad-CAM*, para entender melhor como o modelo toma decisões e quais características são relevantes para a detecção de cada tipo de arritmia. Além disso, a coleta e o uso de conjuntos de dados maiores e mais diversificados, rotulados a partir da extração do aparelho MP-IoT [8] junto a um médico especialista em cardiologia, podem melhorar o desempenho a capacidade do modelo RHC5.

Em conclusão, o desenvolvimento desta rede híbrida de inteligência artificial representa um avanço importante na detecção de arritmias cardíacas e seu acompanhamento. Esperamos que as descobertas e contribuições apresentadas neste estudo sejam úteis em conjunto com o aparelho MP-IoT e a plataforma *eProHealth*, a fim de aprimorar ainda mais os métodos de diagnóstico e monitoramento cardíaco e inspirar novas pesquisas brasileiras nessa área.

6 Agradecimentos

Gostaria de expressar um profundo agradecimento ao orientador, Professor Marcelo Trindade Rebonatto pela orientação, oportunidades de pesquisas, *network* e apoio constantes ao longo deste trabalho. Também agradeço ao pesquisador Luiz Eduardo Schardong Spalding pelo apoio e ao desenvolvimento do aparelho MP-IoT [8]; a Larissa Brandão Pasinato por disponibilizar os dados do simulador *Fluke*; ao professor Jeangrei Emanoelli Veiga

pelo apoio da plataforma *eProHealth* [22]; ao professor Rafael Rieder por orientações das camadas convolucionais e aos professores Rafael Heitor Bordini e Denise Bandeira por orientações iniciais e sugestões de construções da rede criada. Agradeço também ao médico Enrique Pokulat pelo auxílio técnico nas anomalias cardíacas.

7 *

Referências

- [1] GRECO, L. et al. Trends in iot based solutions for health care: Moving ai to the edge. *Pattern Recognition Letters*, v. 135, p. 346–353, 2020.
- [2] AKMANDOR, A. O.; JHA, N. K. Smart health care: An edge-side computing perspective. *IEEE Consumer Electronics Magazine*, v. 7, n. 1, p. 29–37, 2018.
- [3] MEEK, S.; MORRIS, F. ABC of clinical electrocardiography.introduction. I-Leads, rate, rhythm, and cardiac axis. *BMJ*, England, v. 324, n. 7334, p. 415–418, fev. 2002.
- [4] RIBEIRO, A. L. P. et al. Cardiovascular health in brazil: Trends and perspectives. *Circulation*, Lippincott Williams and Wilkins, v. 133, p. 422–433, Jan 2016. ISSN 15244539.
- [5] BRANT, L. C. C. et al. Burden of cardiovascular diseases attributable to risk factors in brazil: data from the "global burden of disease 2019"study. *Rev Soc Bras Med Trop*, Brazil, v. 55, n. "suppl 1", p. e0263, jan 2022.
- [6] ZHENG, J. et al. Optimal multi-stage arrhythmia classification approach. *Scientific Reports*, 2020.
- [7] OLIVEIRA, V. F. L. D. et al. Arritmias cardíacas no contexto da pandemia da covid-19: Uma revisão integrativa da literatura / cardiac arrhythmias in the covid-19 pandemic context: An integrative literature review. *Brazilian Journal of Health Review*, South Florida Publishing LLC, v. 4, p. 12937–12958, 6 2021.
- [8] ACADÊMICAS, P. *Aparelho Multiclinico MP IoT*. 2022.
- [9] GOLDBERGER, A. L. et al. PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation*, v. 101, n. 23, p. e215–e220, 2000. Circulation Electronic Pages: <http://circ.ahajournals.org/content/101/23/e215.full> PMID:1085218; doi: 10.1161/01.CIR.101.23.e215.
- [10] COOK, D. A.; OH, S.-Y.; PUSIC, M. V. Accuracy of physicians' electrocardiogram interpretations: A systematic review and meta-analysis. *JAMA Intern Med*, United States, v. 180, n. 11, p. 1461–1471, nov. 2020.
- [11] MANT, J. et al. Accuracy of diagnosing atrial fibrillation on electrocardiogram by primary care practitioners and interpretative diagnostic software: analysis of data from screening for atrial fibrillation in the elderly (SAFE) trial. *BMJ*, England, v. 335, n. 7616, p. 380, jun. 2007.
- [12] CHON, K. H.; MC MANUS, D. D. Detection of atrial fibrillation using a smartwatch. *Nat Rev Cardiol*, England, v. 15, n. 11, p. 657–658, nov. 2018.
- [13] O'SULLIVAN, J. W. et al. Accuracy of smartphone camera applications for detecting atrial fibrillation: A systematic review and meta-analysis. *JAMA Netw Open*, United States, v. 3, n. 4, p. e202064, abr. 2020.
- [14] AHSAN, M. M.; SIDDIQUE, Z. Machine learning-based heart disease diagnosis: A systematic literature review. *Artificial Intelligence in Medicine*, v. 128, p. 102289, 2022. ISSN 0933-3657. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0933365722000549>>.
- [15] MOHAMMADI, M. et al. Deep learning for iot big data and streaming analytics: A survey. *IEEE Communications Surveys & Tutorials*, v. 20, n. 4, p. 2923–2960, 2018. Disponível em: <<https://doi.org/10.1109/COMST.2018.2844341>>.
- [16] SHERSTINSKY, A. Fundamentals of recurrent neural network (rnn) and long short-term memory (lstm) network. *Physica D: Nonlinear Phenomena*, v. 404, p. 132306, 2020. ISSN 0167-2789. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0167278919305974>>.

- [17] ZHU, F. et al. Electrocardiogram generation with a bidirectional lstm-cnn generative adversarial network. *Scientific Reports*, v. 1, 05 2019. ISSN 2045-2322. Disponível em: <<https://doi.org/10.1038/s41598-019-42516-z>>.
- [18] FAN, X. et al. Structured self-attention architecture for graph-level representation learning. *Pattern Recognition*, v. 100, p. 107084, 2020. ISSN 0031-3203. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0031320319303851>>.
- [19] LUZ, E. J. da S. et al. Ecg-based heartbeat classification for arrhythmia detection: A survey. *Computer Methods and Programs in Biomedicine*, v. 127, p. 144–164, 2016. ISSN 0169-2607. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0169260715003314>>.
- [20] GERING M.D., F. L. E. et al. *CHOU'S ELECTROCARDIOGRAPHY IN CLINICAL PRACTICE*. United States: SAUNDERS ELSEVIER, 2008.
- [21] FENGLER, B. T.; BRADY, W. J.; PLAUTZ, C. U. Atrial fibrillation in the wolff-parkinson-white syndrome: Ecg recognition and treatment in the ed. *The American Journal of Emergency Medicine*, v. 25, n. 5, p. 576–583, 2007. ISSN 0735-6757. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0735675706004505>>.
- [22] APPS, V. *Monitora-PA*. Disponível em: <<https://play.google.com/store/apps/details?id=br.upf.elifestyle>>.
- [23] AD8232. Disponível em: <<https://www.analog.com/media/en/technical-documentation/data-sheets/ad8232.pdf>>.
- [24] HICKS, S. A. et al. On evaluation metrics for medical applications of artificial intelligence. *Scientific Reports*, v. 12, 2022. ISSN 2045-2322. Disponível em: <<https://doi.org/10.1038/s41598-022-09954-8>>.
- [25] NASER, M. Z.; ALAVI, A. H. Error metrics and performance fitness indicators for artificial intelligence and machine learning in engineering and sciences. *JO - Architecture, Structures and Construction*, 2021. ISSN 2730-9894. Disponível em: <<https://doi.org/10.1007/s44150-021-00015-8>>.
- [26] GUPTA, H. V. et al. Decomposition of the mean squared error and nse performance criteria: Implications for improving hydrological modelling. *Journal of Hydrology*, v. 377, n. 1, p. 80–91, 2009. ISSN 0022-1694. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0022169409004843>>.
- [27] NASER, M. Z.; ALAVI, A. Insights into performance fitness and error metrics for machine learning. *CoRR*, abs/2006.00887, 2020. Disponível em: <<https://arxiv.org/abs/2006.00887>>.
- [28] ČALASAN, M.; Abdel Aleem, S. H.; ZOBA, A. F. On the root mean square error (rmse) calculation for parameter estimation of photovoltaic models: A novel exact analytical solution based on lambert w function. *Energy Conversion and Management*, v. 210, p. 112716, 2020. ISSN 0196-8904. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0196890420302545>>.
- [29] DRAPER, C. et al. Estimating root mean square errors in remotely sensed soil moisture over continental scale domains. *Remote Sensing of Environment*, v. 137, p. 288–298, 2013. ISSN 0034-4257. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S003442571300206X>>.
- [30] QI, J. et al. On mean absolute error for deep neural network based vector-to-vector regression. *IEEE Signal Processing Letters*, v. 27, p. 1485–1489, 2020.
- [31] CHICCO, D.; WARRENS, M. J.; JURMAN, G. The coefficient of determination r-squared is more informative than smape, mae, mape, mse and rmse in regression analysis evaluation. *PeerJ Computer Science*, 2021. Disponível em: <<https://doi.org/10.7717/peerj-cs.623>>.
- [32] GRANDINI, M.; BAGLI, E.; VISANI, G. *Metrics for Multi-Class Classification: an Overview*. arXiv, 2020. Disponível em: <<https://arxiv.org/abs/2008.05756>>.
- [33] BHUYAN, H. K. et al. Covid-19 diagnosis system by deep learning approaches. *Expert Systems*, v. 39, n. 3, p. e12776, 2022. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1111/exsy.12776>>.

- [34] DAVIS, J.; GOADRICH, M. The relationship between precision-recall and roc curves. In: . [S.l.: s.n.], 2006. v. 06.
- [35] AGARWAL, N. et al. Machine learning applications for iot healthcare. p. 129–144, 2021.
- [36] ZHOU, H. et al. Population analysis of mortality risk: Predictive models from passive monitors using motion sensors for 100,000 uk biobank participants. *PLOS Digital Health*, Public Library of Science, v. 1, n. 10, p. 1–22, 10 2022. Disponível em: <<https://doi.org/10.1371/journal.pdig.0000045>>.
- [37] SCHWALBE, N.; WAHL, B. Artificial intelligence and the future of global health. *The Lancet*, v. 395, n. 10236, p. 1579–1586, 2020. ISSN 0140-6736. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0140673620302269>>.
- [38] CHEN, Y.-w. et al. Learning to predict in-hospital mortality risk in the intensive care unit with attention-based temporal convolution network. *BMC Anesthesiology*, v. 22, p. Article 54, 2022.
- [39] SIMANJUNTAK, J. E. S.; KHODRA, M. L.; MANULLANG, M. C. T. Design methods of detecting atrial fibrillation using the recurrent neural network algorithm on the arduino ad8232 ecg module. *IOP Conference Series: Earth and Environmental Science*, IOP Publishing, v. 537, n. 1, p. 012022, jul 2020. Disponível em: <<https://dx.doi.org/10.1088/1755-1315/537/1/012022>>.
- [40] OLIVEIRA, R. et al. Um método ensemble para classificação de arritmias: Uma avaliação com mais de 10 mil registros de sinais de ecg. In: *Anais do XXII Simpósio Brasileiro de Computação Aplicada à Saúde*. Porto Alegre, RS, Brasil: SBC, 2022. p. 13–24. ISSN 2763-8952. Disponível em: <<https://sol.sbc.org.br/index.php/sbcas/article/view/21616>>.
- [41] FAUST, O. et al. Automated detection of atrial fibrillation using long short-term memory network with rr interval signals. *Computers in Biology and Medicine*, v. 102, p. 327–335, 2018. ISSN 0010-4825. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0010482518301847>>.
- [42] LIU, S. et al. Mgnn: A multiscale grouped convolutional neural network for efficient atrial fibrillation detection. *Computers in Biology and Medicine*, v. 148, p. 105863, 2022. ISSN 0010-4825. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0010482522006175>>.
- [43] HE, R. et al. Automatic detection of atrial fibrillation based on continuous wavelet transform and 2d convolutional neural networks. *Frontiers in Physiology*, v. 9, 2018. ISSN 1664-042X. Disponível em: <<https://www.frontiersin.org/articles/10.3389/fphys.2018.01206>>.
- [44] ZHENG, J.; GUO, H.; CHU, H. *A large-scale 12-lead electrocardiogram database for arrhythmia study (version 1.0.0)*. 2022.
- [45] WAGNER, P. et al. *PTB-XL, a large publicly available electrocardiography dataset*. 2022. Disponível em: <<https://physionet.org>>.
- [46] BAI, Y.-W. et al. Adjustable 60hz noise reduction by a notch filter for ecg signals. In: *Proceedings of the 21st IEEE Instrumentation and Measurement Technology Conference (IEEE Cat. No.04CH37510)*. [S.l.: s.n.], 2004. v. 3, p. 1706–1711.
- [47] KARRI, M.; ANNAVARAPU, C. S. R. A real-time embedded system to detect qrs-complex and arrhythmia classification using lstm through hybridized features. *Expert Systems with Applications*, v. 214, p. 119221, 2023. ISSN 0957-4174. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0957417422022394>>.
- [48] JAGTAP, S. K.; UPLANE, M. O impacto da filtragem digital na análise de ecg: aplicação do filtro butterworth. In: *Conferência Internacional de Tecnologia de Comunicação, Informação e Computação de 2012 (ICCICT)*. [S.l.: s.n.], 2012. p. 1–6.
- [49] SELESNICK, I.; BURRUS, C. Generalized digital butterworth filter design. *IEEE Transactions on Signal Processing*, v. 46, n. 6, p. 1688–1694, 1998.

- [50] JAGDEEP, R.; SORA, M.; SHARMA, L. Correção da linha de base do ecg usando o método de estimativa de regressão. In: *2019 4th International Conference on Internet of Things: Smart Innovation and Usages (IoT-SIU)*. [S.l.: s.n.], 2019. p. 1–5.
- [51] GALLAGHER, A. Detection of linear and cubic interpolation in jpeg compressed images. In: *The 2nd Canadian Conference on Computer and Robot Vision (CRV'05)*. [S.l.: s.n.], 2005. p. 65–72.
- [52] JEONG, J. et al. Electrocardiogram sampling frequency range acceptable for heart rate variability. p. 198–206, 2018. Disponível em: <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6085204/#B17>>.
- [53] SRIVASTAVA, N. et al. *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. 2014. 1929–1958 p.
- [54] WANG, M. et al. A high-speed and low-complexity architecture for softmax function in deep learning. In: *2018 IEEE Asia Pacific Conference on Circuits and Systems (APCCAS)*. [S.l.: s.n.], 2018. p. 223–226.
- [55] REDDI, S. J.; KALE, S.; KUMAR, S. On the convergence of adam and beyond.
- [56] HO, Y.; WOOKEY, S. The real-world-weight cross-entropy loss function: Modeling the costs of mislabeling. *IEEE Access*, v. 8, p. 4806–4813, 2020.
- [57] ARLOT, S.; CELISSE, A. A survey of cross-validation procedures for model selection. *Statistics Surveys*, v. 4, p. 40–79, 2010. ISSN 19357516.
- [58] FLUKE. *ProSim 4 Vital Signs Patient Simulator*. 2023. Disponível em: <<https://www.flukebiomedical.com/>>.

Anexos

A Exemplo do arquivo JS02082.hea da derivação I da base 1**Exemplo do arquivo JS02082.hea da derivação I da base 1**

A seguir, dados de exemplos do arquivo .hea em ordem crescente, da esquerda para a direita, a fim de entendimento da função dessas variáveis: **JS02082.mat 16+24 1000/mV 16 0 -49 15041 0 I**. Essa estrutura se repete na base de dados PTBXL [45].

A variável **16+24** indica o número de amostras por segundo do sinal de ECG. Nesse caso, são 16 amostras por segundo (para o canal aVR) e 24 amostras por segundo (para os outros canais); **1000/mV** a unidade de medida do sinal de ECG. Nesse caso, o sinal foi amplificado para uma escala de 1000 microvolts por milivolt. **16** o número de canais do sinal de ECG; **0** o valor do ponto de referência do sinal de ECG; **-49** o valor mínimo do sinal de ECG; **15041** o valor máximo do sinal de ECG; **0** o campo reservado para futuras implementações; **I** o nome da derivação I do ECG; **#Age** representa informações sobre a idade do paciente; **#Sex** representa informações sobre o sexo do paciente; **#Dx** representa a classificação Internacional de Doenças (CID): informações sobre o diagnóstico do paciente de acordo com a codificação CID; **#Rx** representa informações sobre o tratamento que o paciente recebeu para sua condição de saúde; **#Hx** representa informações sobre o histórico médico do paciente, incluindo doenças anteriores, cirurgias, medicamentos utilizados, entre outros; **#Sx** representa informações sobre os sintomas apresentados pelo paciente, como dor no peito, palpitações, falta de ar, entre outros.

Tabela 7: Tabela da Base arritmia

Variável	Descrição
JS02082.mat	nome do arquivo do sinal de ECG.
16+24	número de amostras por segundo do sinal de ECG. Nesse caso, são 16 amostras por segundo (para o canal aVR) e 24 amostras por segundo (para os outros canais).
1000/mV	unidade de medida do sinal de ECG. Nesse caso, o sinal foi amplificado para uma escala de 1000 microvolts por milivolt.
16	número de canais do sinal de ECG.
0	valor do ponto de referência do sinal de ECG.
-49	valor mínimo do sinal de ECG.
15041	valor máximo do sinal de ECG.
0	campo reservado para futuras implementações.
I	nome da derivação I do ECG.
#Age	Representa informações sobre a idade do paciente.
#Sex	Representa informações sobre o sexo do paciente.
#Dx	Classificação Internacional de Doenças (CID): Representa informações sobre o diagnóstico do paciente de acordo com a codificação CID.
#Rx	Tratamento: Representa informações sobre o tratamento que o paciente recebeu para sua condição de saúde.
#Hx	Histórico Médico: Representa informações sobre o histórico médico do paciente, incluindo doenças anteriores, cirurgias, medicamentos utilizados, entre outros.
#Sx	Sintomas: Representa informações sobre os sintomas apresentados pelo paciente, como dor no peito, palpitações, falta de ar, entre outros.

A EXEMPLO DO ARQUIVO JS02082.HEA DA DERIVAÇÃO I DA BASE 1

A seguir é descrito os processos utilizados para a construção da base PTBXL referente a classificação normal:

- Remover ECGs que apresentavam problemas nos eletrodos (electrodes_problems no arquivo ptbxl_database.csv definido com valor 1)
- Selecionar apenas quando o valor da variável NORM em scp_codes for igual a 100 no arquivo scp_statements.csv
- Apenas dados que foram validados por humanos (validated_by_human no arquivo ptbxl_database.csv definido com valor 1)
- Cada sinal foi dividido por 10 a fim de deixar na mesma escala dos valores de saídas do aparelho MP.