

TRABALHO FINAL DE CURSO

Estratégias Computacionais para Detecção de Epilepsia em EEG: Abordagem em *pipeline versus end-to-end*

Computational Strategies for Epilepsy Detection in EEG: Pipeline versus End-to-End Approaches

André Gasoli Sichelero¹ and Marcelo Trindade Rebonatto²

¹Universidade de Passo Fundo, Instituto de Ciências Exatas e Geociências, Ciência da Computação

Abstract

Electroencephalography plays a pivotal role in diagnosing neurological disorders such as epilepsy. This study contrasts two computational strategies for seizure detection: a feature engineering pipeline utilizing the Binary Dragonfly Algorithm for feature selection followed by a Deep Neural Network, and an end-to-end architecture, the Hybrid Bidirectional Convolutional Network 5. Employing a paired experimental design with common random seeds on the Bonn dataset, the trade-off between interpretability and generalization was evaluated. Results indicate that while the pipeline approach achieved high sensitivity for ictal events, it exhibited instability in feature selection and lower specificity for the interictal state. Conversely, the hybrid architecture demonstrated superior statistical robustness and greater generalization capacity, significantly enhancing the detection of interictal patterns (95.11% recall versus 80.00%), a 15.11 percentage point improvement critical for clinical reliability. It is concluded that while pipelines offer granular explainability, identifying potential model biases, end-to-end models provide greater reliability for clinical screening and continuous monitoring.

Keywords: Artificial Intelligence; Genetic Algorithms; Machine Learning; Dragonfly Algorithm; Hybrid Bidirectional Convolutional Network.

Resumo

A eletroencefalografia desempenha um papel fundamental no diagnóstico de distúrbios neurológicos como a epilepsia. Este estudo contrasta duas estratégias computacionais para a detecção de crises: um *pipeline* de aprendizado de máquina que utiliza o Algoritmo da Libélula Binário para seleção de características seguido por uma Rede Neural Profunda, e uma arquitetura *end-to-end*, a Rede Híbrida Convolutacional Bidirecional. Utilizando um desenho experimental pareado com sementes aleatórias comuns no *dataset* de Bonn, avaliou-se o balanço entre interpretabilidade e generalização. Os resultados indicam que, embora a abordagem de *pipeline* tenha alcançado alta sensibilidade para eventos ictais, apresentou instabilidade na seleção de atributos e menor especificidade para o estado interictal. Em contrapartida, a arquitetura híbrida demonstrou robustez estatística superior e maior capacidade de generalização, elevando significativamente a detecção de padrões interictais (95,11% de *recall* na classe Interictal contra 80,00%). Conclui-se que, enquanto os *pipelines* oferecem explicabilidade granular, os modelos *end-to-end* fornecem maior confiabilidade para triagem clínica e monitoramento contínuo.

Palavras-Chave: Inteligência Artificial; Algoritmos Genéticos; Aprendizado de Máquina; Algoritmo da Libélula; Rede Híbrida Convolutacional Bidirecional.

1 Introdução

Na engenharia biomédica, a análise automatizada de sinais eletroencefalográficos (EEG) para o diagnóstico da epilepsia constitui um desafio de pesquisa de alta relevância clínica e computacional (Acharya, Sreeja, Swapna, Martis e Suri, 2013; Subasi, 2019). A literatura atual delinea duas macro-tendências algorítmicas para a detecção de crises: o paradigma clássico em *pipeline* e a abordagem integrada *end-to-end*.

A primeira estratégia baseia-se na decomposição sequencial do problema: extração manual de características (*feature engineering*), seguida por seleção otimizada via meta-heurísticas bioinspiradas e, por fim, classificação (Guyon e Elisseeff, 2003; Emary et al., 2016; Mirjalili e Hashim, 2016; Martínez-Vargas et al., 2022). A segunda estratégia rompe com a modularidade ao empregar arquiteturas de aprendizado profundo (*Deep Learning*) que aprendem representações latentes diretamente dos dados brutos, unificando a extração e a classificação em um modelo diferenciável (Roy et al., 2019; Lu e Triesch, 2019; Shoeibi et al., 2021).

Apesar da vasta produção acadêmica em ambas as vertentes, observa-se uma carência de estudos que realizem uma comparação direta e controlada sob as mesmas condições experimentais (Acharya et al., 2021; Martínez-Vargas et al., 2022). A maioria das propostas foca na maximização de métricas isoladas, negligenciando a análise da variância estocástica, a sensibilidade a hiperparâmetros e os *trade-offs* de interpretabilidade (Cherukuvada e Kayalvizhi, 2023; Chanhar H., 2021).

Esta ausência de comparações diretas é particularmente problemática quando se considera que estudos isolados frequentemente reportam métricas de acurácia superiores a 95% (Yogarajan et al., 2023; Al-Ghamdi e Sheikh, 2024), mas falham em validar a estabilidade estocástica dessas métricas através de múltiplas execuções com diferentes partições de dados. A reprodutibilidade dos resultados, portanto, permanece uma questão em aberto.

Diante desse cenário, o presente estudo conduz uma análise comparativa rigorosa entre um *pipeline* de otimização estocástica — composto pelo Algoritmo da Libélula Binário (*Binary Dragonfly Algorithm* - BDA) (Emary et al., 2016; Mirjalili e Hashim, 2016) em abordagem *wrapper* com K-vizinhos mais próximos (*K-Nearest Neighbors* - KNN) e classificação via Rede Neural Profunda (*Deep Neural Network* - DNN) — e uma arquitetura *end-to-end* do estado da arte, a Rede Híbrida Convolutacional Bidirecional (RHCB5) (Maggioni e Rebonatto, 2023, 2024). Diferentemente de revisões narrativas, esta pesquisa adota um delineamento experimental pareado com controle de sementes aleatórias (*Common Random Numbers* - CRN), visando isolar o desempenho intrínseco de cada método na detecção de padrões ictais e interictais.

O trabalho está organizado da seguinte forma: a Seção 2 fundamenta os conceitos de EEG e epilepsia. A Seção 3 discute o estado da arte e as arquiteturas selecionadas. A Seção 4 detalha o protocolo experimental rigoroso e os materiais. A Seção 5 apresenta a implementação, os resultados comparativos e a análise de interpretabilidade dos modelos de aprendizado de máquina. Por fim, a Seção 6 conclui o estudo com diretrizes para aplicação clínica e recomendações de trabalhos futuros.

2 Fundamentação teórica

Esta seção estabelece as premissas neurofisiológicas e os desafios de processamento de sinais que fundamentam as estratégias computacionais adotadas. Discute-se a natureza estocástica do sinal EEG, a taxonomia atualizada das crises epiléticas e as limitações das técnicas clássicas de extração de características.

2.1 Eletroencefalograma

O Eletroencefalograma (EEG) constitui o registro da atividade elétrica cortical, resultante da somatória temporal de potenciais pós-sinápticos em grandes populações de neurônios piramidais (Schomer e Lopes da Silva, 2018). Captado de forma não invasiva por meio de múltiplos eletrodos posicionados sobre o couro cabeludo — cuja disposição geralmente segue padrões internacionais, como o sistema 10-20 (Jasper, 1958; Husain, 2023) —, o sinal é caracterizado por baixa amplitude (ordem de μV) e alta suscetibilidade a artefatos e ruídos (Pillai e Sperling, 2007).

Clinicamente, o EEG é uma técnica diagnóstica de grande valor. Ele permite examinar o funcionamento elétrico do cérebro em tempo real, com alta resolução temporal, sendo indispensável na investigação de diversas condições neurológicas. Suas aplicações abrangem o diagnóstico e classificação da epilepsia, a avaliação de lesões cerebrais, o monitoramento da profundidade anestésica, o estudo de distúrbios do sono e o desenvolvimento de interfaces cérebro-computador (*Brain-Computer Interface* - BCI) (Qi et al., 2020).

A análise visual e computacional do EEG frequentemente se baseia na identificação e quantificação de diferentes padrões rítmicos, conhecidos como ondas cerebrais. A classificação mais comum dessas ondas é baseada em sua faixa de frequência. No entanto, outras características como localização no escalpo, amplitude, morfologia da onda, continuidade (ritmo contínuo ou intermitente) e reatividade a estímulos (como abertura e fechamento dos olhos) também são importantes para a interpretação (Schomer e Lopes da Silva, 2018).

Entre os principais ritmos cerebrais em humanos está a onda *Delta* (δ), com frequência entre 0.5 e 4 Hz, predominante durante o sono profundo em adultos. A onda *Theta* (θ), entre 4 e 8 Hz, é comum em crianças acordadas e em adultos durante o sono leve. A onda *Alpha* (α), de 8 a 13 Hz, é o ritmo dominante em adultos normais em vigília relaxada, especialmente com os olhos fechados, sendo atenuada pela abertura dos olhos e esforço mental. As ondas *Beta* (β), entre 13 e 30 Hz, são comuns em adultos acordados e alertas (Teplan, 2002). As ondas *Gamma* (γ), com frequências acima de 30 Hz (podendo alcançar mais de 80 Hz), estão associadas a funções cognitivas superiores, como percepção e atenção.

No contexto da epilepsia, contudo, o interesse se estende às Oscilações de Alta Frequência (HFOs), como *ripples* (80–200 Hz) e *fast ripples* (200–500 Hz), que são marcadores potenciais da zona epileptogênica (Pfurtscheller e Lopes da Silva, 1999; Schomer e Lopes da Silva, 2018; Husain, 2023; Engel Jr. et al., 2024). Embora a presença ou ausência, focal ou generalizada, destas frequências na população possa significar diferentes patologias cerebrais, no contexto da epilepsia, nenhuma banda de frequência isolada é, por si só, a mais determinante para o diagnóstico. A relevância patoló-

gica também não depende apenas da potência nessas bandas, mas da identificação de padrões morfológicos transitórios e anômalos que rompam a atividade de fundo (*background*).

2.2 Definição e Classificação da Epilepsia

A epilepsia é definida conceitualmente pela predisposição persistente do cérebro em gerar crises epiléticas, eventos caracterizados por descargas neuronais excessivas e hipersíncronas (Engel Jr. et al., 2024). A classificação atual da Liga Internacional Contra a Epilepsia (ILAE - 2025) (Beniczky, 2025) categoriza as crises primariamente pelo seu início: **focal** (originando-se em redes neurais limitadas a um hemisfério), **generalizado** (envolvendo ambos os hemisférios simultaneamente desde o início) ou **desconhecido** (quando o início não foi observado ou permanece inconclusivo) (Epilepsy Foundation, 2025).

As crises focais, que constituem aproximadamente 60% dos casos de epilepsia (Engel Jr. et al., 2024), subdividem-se conforme o nível de comprometimento da consciência durante o evento. Crises focais com *preservação da consciência* (anteriormente denominadas “simples”) mantêm o paciente plenamente consciente, manifestando-se por sintomas motores localizados, sensitivos, ou psíquicos. Em contrapartida, crises focais com *comprometimento da consciência* (anteriormente “complexas”) caracterizam-se por alteração do nível de alerta.

A epilepsia do lobo temporal, etiologia específica dos registros utilizados neste estudo (*dataset* de Bonn (Arbeitsgruppen AG Lehnertz Neurophysik, Epileptologie, Universitätsklinikum Bonn, 2001)), é a forma mais comum de epilepsia focal em adultos, correspondendo a cerca de 40% das epilepsias focais (Engel Jr. et al., 2024). Clinicamente, manifesta-se tipicamente por crises com comprometimento da consciência, precedidas por uma aura característica. Durante a crise, observam-se pausas comportamentais (*behavioral arrest*), olhar fixo e automatismos gestuais. Do ponto de vista eletrofisiológico, as crises originam-se predominantemente em estruturas mesiais do lobo temporal, como o hipocampo e a amígdala, manifestando-se no EEG intracraniano por atividade rítmica *Theta* de baixa tensão que evolui progressivamente em amplitude e frequência (Noachtar e Beier, 2021).

Do ponto de vista de modelagem computacional, a distinção crítica reside nos três estados funcionais do paciente epilético: o estado **Ictal** (durante a crise), caracterizado por descargas síncronas de alta amplitude e frequência crescente; o estado **Interictal** (entre crises), marcado por descargas epileptiformes transitórias isoladas — espículas, ondas agudas ou complexos espícula-onda — que representam a assinatura eletrofisiológica da zona epileptogênica mesmo na ausência de manifestações clínicas (Noachtar e Beier, 2021); e o estado **Normal**, correspondente à atividade de fundo cerebral de indivíduos saudáveis. A correta discriminação do estado Interictal é particularmente desafiadora para sistemas automatizados devido à sua sutileza morfológica — as descargas possuem duração de 20-70 ms e amplitude de apenas 50-200 μV — e semelhança estatística com artefatos fisiológicos (como atividade muscular ou movimentos oculares), representando a principal causa de falsos positivos em algoritmos de monitoramento (Noachtar e Beier, 2021; Schomer e Lopes da Silva, 2018).

2.3 Desafios no Processamento de Sinais EEG

O processamento de sinais EEG para avaliação da epilepsia enfrenta desafios significativos. Um dos maiores desafios reside nos artefatos — sinais elétricos indesejados de fontes fisiológicas (atividade muscular, ocular, cardíaca, sudorese) ou não fisiológicas (movimento de eletrodos, interferência da rede elétrica (60 Hz)) — que frequentemente possuem amplitudes superiores ao sinal de interesse e podem mimetizar descargas epiléticas, levando a interpretações errôneas (Subasi, 2019; Pillai e Sperling, 2007; Islam et al., 2018). Adicionalmente, a baixa resolução espacial do EEG, devido à condução de volume pelo crânio e tecidos moles, reflete a atividade somada de grandes áreas corticais, limitando a localização precisa da origem da atividade (Schomer e Lopes da Silva, 2018).

Os sinais EEG são também inerentemente não estacionários, com suas propriedades estatísticas (como média, variância e espectro de frequência) mudando ao longo do tempo, o que reflete a natureza dinâmica da atividade cerebral em resposta a diferentes estados mentais, níveis de alerta e processos cognitivos. Os perfis de EEG também podem variar consideravelmente entre indivíduos, mesmo em condições semelhantes, devido a fatores anatômicos e fisiológicos. Ademais, o EEG de um mesmo indivíduo pode variar dependendo do estado de alerta, fadiga, uso de medicamentos e outros fatores (Schomer e Lopes da Silva, 2018).

Para mitigar esses problemas, etapas de pré-processamento de sinais são indispensáveis, incluindo filtragem (passa-banda, *notch*) e técnicas de supressão de artefatos. Após essa etapa, a extração de características do sinal (decomposição) visa transformar os segmentos de EEG em um conjunto de valores numéricos que capturam informações discriminativas. Estas podem ser extraídas em diferentes domínios (Welch, 1967; Pfurtscheller e Lopes da Silva, 1999). No domínio do tempo, incluem-se medidas estatísticas como média, variância e parâmetros de Hjorth. No domínio da frequência, utiliza-se a Transformada Rápida de Fourier (*Fast Fourier Transform* - FFT) para obter a Densidade Espectral de Potência (*Power Spectral Density*), revelando a distribuição de energia do sinal pelas bandas de frequência. Para a análise de tempo-frequência, técnicas como a Transformada Wavelet (*Wavelet Transform* - WT), incluindo suas variantes Discreta e Estacionária, são amplamente utilizadas em sinais não estacionários, fornecendo informações sobre a frequência e sua localização temporal. Por fim, medidas de complexidade e não linearidade, como a entropia, quantificam a regularidade dos sinais EEG, auxiliando na diferenciação de estados cerebrais.

Na avaliação da epilepsia, as Descargas Epileptiformes Interictais (DEIs) — eventos transitórios como espículas, ondas agudas ou complexos espícula-onda (vide Figura 1) — são o marcador eletrofisiológico mais direto (Schomer e Lopes da Silva, 2018; Noachtar e Beier, 2021; Engel Jr. et al., 2024). O padrão e a distribuição das DEIs são cruciais para diferenciar epilepsias focais e generalizadas, distinção que orienta o tratamento e o prognóstico (Engel Jr. et al., 2024).

A elevada complexidade envolvida na interpretação do EEG em indivíduos com epilepsia (Pillai e Sperling, 2007), aliada à presença de ruído, não estacionariedade do sinal e limitada resolução espacial, evidencia de forma contundente a necessidade de métodos automatizados de análise robustos.




Figura 1: Descargas interictais epilépticas em múltiplos canais de EEG. (A) Traçados de múltiplos canais com marcadores laranja para descargas; (B) Taxa de DEIs por minuto dos dois hemisférios; (C) Mapa das posições dos eletrodos no cérebro; (D) espectrograma de um eletrodo. (Falach et al., 2024) Nota-se a brevidade temporal (20-70 ms) e a distribuição focal das descargas, características que dificultam a detecção automatizada

Tais abordagens metodológicas devem ser capazes de lidar adequadamente com incertezas e de identificar, de modo confiável, características discriminativas e variáveis relevantes. Nesse contexto, etapas de pré-processamento, procedimentos de remoção de artefatos e estratégias de otimização para seleção de atributos estatisticamente significativos configuram-se como processos essenciais a serem conduzidos antes de qualquer etapa de análise ou classificação (Guyon e Elisseeff, 2003; Dash e Liu, 1997).

3 Revisão de literatura

Esta revisão contextualiza as duas filosofias dominantes para classificação de EEG: o paradigma em *pipeline*, fundamentado na engenharia explícita de características, e a abordagem *end-to-end*, baseada no aprendizado automático de representações latentes. Analisam-se aqui as técnicas fundamentais, as implementações do estado da arte e os compromissos intrínsecos a cada vertente, estabelecendo as bases teóricas para a comparação experimental proposta.

3.1 Abordagem em Pipeline: Engenharia e Seleção de Atributos

A abordagem em *pipeline* decompõe o problema da detecção de epilepsia em etapas modulares e sequenciais. O sucesso deste paradigma depende criticamente da eficácia de cada um desses módulos interconectados e da capacidade de transformar a alta dimensionalidade do sinal bruto em uma representação compacta (*embedding*) que maximize a separabilidade linear entre as classes, antes de submetê-la a um classificador.

3.1.1 Extração de Atributos de EEG

Sinais de EEG são séries temporais não estacionárias e estocásticas, tornando o uso direto de amostras brutas ineficiente para classificadores tradicionais (Lotte et al., 2018). A extração de atributos visa mitigar essa limitação. Neste domínio, a Transformada Wavelet Estacionária (*Stationary Wavelet Transform* - SWT) consolidou-se como técnica preferencial frente à FFT, dada sua propriedade de invariância à translação e capacidade de preservar a resolução temporal em múltiplas escalas de frequência (Adeli et al., 2003; Subasi, 2010).

A decomposição via SWT gera coeficientes que alimentam o cálculo de descritores estatísticos (média, variância, curtose), medidas de complexidade (entropia) e parâmetros de mobilidade de Hjorth (Hjorth, 1970; Acharya, Sree, Swapna, Martis e Suri, 2013). Entretanto, a geração exaustiva desses descritores precipita a “maldição da dimensionalidade” (*curse of dimensionality*) (Guyon e Elisseeff, 2003). Espaços de características excessivamente densos induzem classificadores ao superajuste (*overfitting*), onde o modelo memoriza o ruído da amostra de treino em detrimento da generalização dos padrões patológicos (Dash e Liu, 1997), exigindo, portanto, uma etapa subsequente de filtragem.

3.1.2 Otimização via Meta-heurísticas Bioinspiradas

A seleção de atributos (*Feature Selection* - FS) constitui um problema de otimização combinatória NP-difícil, visando identificar o subconjunto $S \subset F$ que maximiza a acurácia preditiva (Molina et al., 2002). Para navegar neste vasto espaço de busca, meta-heurísticas bioinspiradas oferecem soluções robustas (Becerra-Rozas et al., 2023). Esses métodos de busca estocástica, frequentemente inspirados em fenômenos naturais ou processos biológicos, são projetados para explorar eficientemente espaços de busca vastos e complexos, encontrando soluções de alta qualidade em um tempo computacional razoável.

O emprego de algoritmos bioinspirados em EEG é uma prática consolidada, com destaque para Algoritmos Genéticos (*Genetic Algorithms* - GA) (Subasi, 2007) e Otimização por Enxame de Partículas (*Particle Swarm Optimization* - PSO) (Kennedy e Eberhart, 1995; Adam et al., 2014; Wang et al., 2022). Contudo, o Algoritmo da Libélula Binário (BDA) (Mirjalili e Hashim, 2016; Emary et al., 2016) emergiu recentemente como uma alternativa superior na prevenção de ótimos locais. Estudos comparativos, como o de Mafarja e Mirjalili (2017), demonstram que o BDA supera o GA e o PSO em convergência e redução de dimensionalidade, validando sua seleção como o otimizador representante do estado da arte para o *pipeline* deste estudo.

3.1.3 Classificação via Redes Neurais Profundas (DNN)

Redes Neurais Profundas (DNNs), especificamente Perceptrons Multicamadas (*Multi Layer Perceptron* - MLP), atuam como aproximadores universais de funções para mapear o vetor de características reduzido às classes clínicas (por exemplo, normal, interictal, ictal). Essas redes possuem múltiplas camadas de neurônios artificiais empilhadas (Goodfellow et al., 2016), cada uma aplicando transformação linear aos dados que recebe, permitindo que a rede “aprenda” representações complexas dos dados. Os parâmetros dessas transformações (pesos e vieses) são ajustados durante o processo de treinamento.

No contexto da análise de EEG, as DNNs oferecem vantagens significativas, entre elas a capacidade de assimilar características relevantes diretamente de dados minimamente pré-processados (Roy et al., 2019) e a modelagem de relações complexas e padrões sutis nos sinais, que podem ser difíceis de capturar com modelos lineares (Lu e Triesch, 2019). Apesar de sua capacidade, o uso de DNNs apresenta desafios: elas demandam grandes volumes de dados rotulados para evitar o *overfitting* e possuem um custo computacional de treinamento elevado. No entanto, sua capacidade de generalização, quando bem regularizada, supera métodos lineares clássicos na análise de sinais biomédicos (Roy et al., 2019).

3.2 Abordagem Integrada: Aprendizado End-to-End

Rompendo com a modularidade, a abordagem *end-to-end* utiliza arquiteturas de *Deep Learning* para unificar a extração de características e a classificação em um único grafo computacional diferenciável. O modelo aprende hierarquias de conceitos diretamente dos dados brutos, eliminando a dependência da engenharia manual de atributos (Roy et al., 2019).

3.2.1 Paradigma de Aprendizado End-to-End

A metodologia propõe o treinamento de modelos capazes de realizar o mapeamento direto de entradas minimamente processadas para a saída desejada, dispensando etapas intermediárias explícitas de engenharia de características. De forma automática e orientada pelos dados, o sistema constrói uma hierarquia de representações latentes: as camadas iniciais especializam-se na detecção de características de baixo nível, como oscilações locais no sinal, ao passo que as camadas profundas consolidam tais elementos em conceitos abstratos e complexos, pertinentes à tarefa de classificação final (Goodfellow et al., 2016).

A vantagem primordial dessa abordagem reside na redução da dependência de conhecimento de domínio específico e do esforço manual exigido para o projeto de extratores eficazes. Tal automatização não apenas otimiza o fluxo de trabalho, mas também viabiliza a descoberta de padrões e biomarcadores inéditos, cuja complexidade poderia transcender a concepção de um especialista humano. Em contrapartida, essa autonomia impõe um custo significativo sob a ótica da interpretabilidade. As características inferidas por redes profundas encontram-se frequentemente distribuídas por milhares de parâmetros, configurando o desafio da “caixa-preta” (*black box*), uma limitação crítica em domínios de alto risco como a medicina, onde a explicabilidade das decisões é fundamental (Sturm et al., 2016).

3.2.2 Arquiteturas Híbridas para Sinais Espaço-Temporais

Os sinais de EEG apresentam uma natureza dupla intrínseca: manifestam padrões morfológicos ou “espaciais” locais dentro de uma janela temporal — a exemplo de complexos espícula-onda — e, simultaneamente, dependências temporais cruciais que evoluem ao longo de sequências de janelas. Uma arquitetura neural fundamentada em um único tipo de camada tende a ser subótima para capturar, com igual eficácia, ambas as facetas dessa informação. Consequentemente, arquiteturas híbridas que combinam diferentes tipos de camadas neurais tornaram-se o estado da arte para a análise de séries temporais complexas (Roy et al., 2019; Shoeibi et al., 2021; Zhang et al., 2024). Nesse contexto, a sinergia mais

prevalente é a combinação de Redes Neurais Convolucionais (*Convolutional Neural Networks* - CNN) e Redes Neurais Recorrentes (*Recurrent Neural Networks* - RNN) (Roy et al., 2019; Shoeibi et al., 2021; Zhang et al., 2024).

As CNNs empregam convoluções unidimensionais (1D-CNN) que operam como bancos de filtros aprendíveis deslizando sobre o sinal (Shoeibi et al., 2021). Cada filtro especializa-se na detecção de padrões morfológicos locais específicos, tais como picos agudos ou oscilações rítmicas. Uma propriedade fundamental da convolução é a invariância à translação, capacidade que permite à rede identificar esses padrões independentemente de sua localização temporal na janela de análise, tornando as 1D-CNNs extratores de características locais altamente eficazes (Shoeibi et al., 2021; Roy et al., 2019; Khan et al., 2023; Goodfellow et al., 2016).

Subsequentemente à extração de padrões morfológicos pelas CNNs, as RNNs são empregadas para analisar a dinâmica sequencial desses elementos. Variantes avançadas, como as redes de Memória de Longo Curto Prazo (*Long Short-Term Memory* - LSTM) e suas versões Bidirecionais (Bi-LSTM), demonstram particular adequação a essa tarefa, projetadas para capturar dependências temporais de longo alcance e manter uma memória contextual de eventos pregressos (Goodfellow et al., 2016; Roy et al., 2019). Especificamente, uma Bi-LSTM processa a sequência em ambas as direções temporais, permitindo que a decisão do modelo seja informada pelo contexto completo do evento no sinal.

3.3 Metodologia de busca e seleção de Trabalhos Relacionados

A revisão da literatura foi estruturada para fundamentar, teórica e tecnicamente, a comparação entre as estratégias de *pipeline* e *end-to-end*. O levantamento bibliográfico, conduzido entre fevereiro e maio de 2025, abrangeu as bases de dados *IEEE Xplore*, *Science Direct*, *PubMed*, *Springer*, *arXiv* e *Google Scholar*. A estratégia de busca empregou combinações de descritores focados em três eixos: o domínio do problema (“*epilepsy detection*”, “*EEG signal processing*”), as técnicas de otimização (“*feature selection*”, “*metaheuristic optimization*”, “*Dragonfly Algorithm*”, “*Particle Swarm Optimization*”, “*Genetic Algorithm*”) e as arquiteturas de aprendizado profundo (“*CNN-LSTM*”, “*end-to-end EEG classification*”, “*deep learning epilepsy*”).

Os critérios de elegibilidade priorizaram: (1) artigos originais publicados no decênio 2015–2025; (2) metodologia minimamente reproduzível com descrição de hiperparâmetros; (3) métricas quantitativas robustas reportadas; e (4) aplicação direta ou transferível ao domínio de sinais neurofisiológicos. Foram excluídos trabalhos sem validação experimental, revisões narrativas sem contribuição metodológica própria e estudos com bases de dados proprietárias não replicáveis.

O levantamento inicial identificou 187 artigos potencialmente relevantes nas bases consultadas. Após triagem por título e resumo, 64 trabalhos foram selecionados para leitura completa. Destes, aplicando-se os critérios de elegibilidade, 28 estudos formaram o corpus final da revisão. O processo completo de triagem, incluindo as razões de exclusão em cada etapa, está resumido no fluxograma PRISMA apresentado na Figura 2. O processo de seleção priorizou a identificação de arquétipos representativos de cada filosofia: para a estratégia de *pipeline*, incluíram-se estudos seminais

sobre meta-heurísticas (GA, PSO, BDA) aplicadas à seleção de atributos em sinais biomédicos (Subasi, 2007; Kennedy e Eberhart, 1997; Adam et al., 2014; Mirjalili e Hashim, 2016; Emary et al., 2016; Mafarja e Mirjalili, 2017), bem como trabalhos que consolidam técnicas de extração de características via transformadas *Wavelet* (Adeli et al., 2003; Subasi, 2010); para a vertente *end-to-end*, focou-se em arquiteturas híbridas CNN-RNN validadas especificamente para EEG (Roy et al., 2019; Lu e Triesch, 2019; Khan et al., 2023; Wang et al., 2024) e trabalhos que demonstram transferibilidade de domínio entre biossinais (Maggioni e Rebonatto, 2023, 2024).




Figura 2: Fluxograma PRISMA detalhando o processo de seleção dos estudos. A partir de 187 registros iniciais, 28 compuseram o corpus final após as etapas de triagem e elegibilidade.

A análise final restringiu-se aos trabalhos que permitissem contextualizar os compromissos entre interpretabilidade e desempenho, bem como aqueles que documentassem falhas de reprodutibilidade ou limitações metodológicas relevantes para o desenho experimental proposto. Esta abordagem criteriosa assegura que a fundamentação teórica reflita o estado da arte atual, legitimando a necessidade de uma comparação controlada e pareada entre as duas filosofias algorítmicas.

3.4 Discussão de Trabalhos Relacionados

A análise detalhada das duas abordagens predominantes revela um cenário de pesquisa rico e complexo, com compromissos fundamentais entre automação, interpretabilidade, desempenho e aplicabilidade clínica. Esta seção final sintetiza as observações da literatura para construir o argumento central que justifica a comparação direta proposta neste trabalho.

3.4.1 Abordagem em pipeline

A literatura que emprega a abordagem em *pipeline* para a análise de EEG é vasta, com grande parte da pesquisa concentrando-se no refinamento das técnicas de seleção de características (FS) (Guyon e Elisseeff, 2003; Martínez-Vargas et al., 2022). Historicamente, estudos seminais utilizaram meta-heurísticas clássicas como GA (Subasi, 2007) e PSO, inclusive suas versões binárias (BPSO) (Kennedy e Eberhart, 1997; Li et al., 2024; Adam et al., 2014; Wang et al., 2022). Entretanto, essas abordagens de primeira geração frequentemente sofrem com a convergência prematura para ótimos locais, especialmente em espaços de busca multimodais complexos, como os gerados por coeficientes *Wavelet*.

Para superar essa limitação de estagnação, a literatura contemporânea evoluiu para meta-heurísticas baseadas em enxame com comportamento dinâmico de exploração e exploração. É neste contexto que o Algoritmo da Libélula (*Dragonfly Algorithm* - DA), proposto por Mirjalili e Hashim (2016), destaca-se como o representante do estado da arte escolhido para este estudo. A justificativa para essa escolha reside em sua comprovada superioridade técnica: Mafarja e Mirjalili (2017) demonstraram, em uma análise comparativa extensiva sobre 18 *datasets*, que a versão binária do algoritmo (BDA) supera consistentemente o GA e o PSO tanto em acurácia quanto na capacidade de redução de atributos, devido ao seu mecanismo híbrido que simula tanto a dispersão (migração) quanto a coesão (caça) das libélulas. No domínio biomédico, a pesquisa também tem explorado hibridizações para refinar o BDA, como o BDA com *Simulated Annealing* (BDA-SA) para escapar de ótimos locais (Chantar H., 2021) ou o BDA com Evolução Diferencial (BDA-DE) para otimizar a seleção de atributos de EEG na detecção de epilepsia (Al-Ghamdi e Sheikh, 2024).

O trabalho de Yogarajan et al. (2023) exemplifica o estado da arte nesta categoria. Ao aplicar o BDA para selecionar atributos de um conjunto massivo gerado por decomposição *Wavelet*, os autores reportaram métricas de desempenho quase perfeitas no *dataset* de Bonn, com 100% de acurácia, sensibilidade e especificidade após uma redução de 85% no espaço de atributos. Este resultado sugere que, quando devidamente otimizado, um classificador simples (como uma DNN rasa) pode atingir a excelência diagnóstica. Contudo, a literatura carece de análises que validem a estabilidade estocástica desses subconjuntos de características selecionados: resta a dúvida se o desempenho advém de biomarcadores robustos ou de um sobreajuste estatístico específico da base de dados utilizada.

3.4.2 Abordagem End-to-end

Paralelamente, a abordagem *end-to-end* convergiu para arquiteturas híbridas desenhadas para capturar a natureza espaço-temporal dos sinais fisiológicos (Roy et al., 2019; Sho-

eibi et al., 2021). A sinergia entre CNNs — para extração de morfologias locais — e unidades recorrentes (LSTM/Bi-LSTM) — para modelagem de dependências temporais — estabeleceu-se como o padrão-ouro na literatura atual (Zhang et al., 2024). Em estudos recentes, as camadas 1D-CNN atuam como extratores de padrões locais e morfológicos do sinal bruto, enquanto as camadas RNN, tipicamente LSTM ou Bi-LSTM, modelam as dependências temporais de longo prazo entre esses padrões (Lu e Triesch, 2019). Diversos estudos recentes validam essa sinergia para a detecção de epilepsia. Wang et al. (2024), por exemplo, empregaram um modelo 1D-CNN-BiLSTM para classificação de EEG, e Khan et al. (2023) utilizaram uma arquitetura similar, destacando sua eficácia na captura de informações espaço-temporais. Outras variações robustas incluem modelos como o *MP-SeizNet* (que utiliza uma CNN para características extraídas por *wavelets* e uma Bi-LSTM para o sinal bruto) (Wang et al., 2024), ou modelos que integram mecanismos de atenção para focar nas partes mais relevantes do sinal (Guhdar et al., 2025).

Embora estudos tenham aplicado essas arquiteturas especificamente ao EEG, observa-se um movimento de convergência na engenharia biomédica, onde arquiteturas bem-sucedidas em um domínio (como a cardiologia) demonstram alta transferibilidade. Ao integrar extração profunda e recorrência bidirecional, tais modelos representam a fronteira da capacidade de generalização, prometendo robustez contra ruídos e variabilidade interpaciente que frequentemente degradam o desempenho de descritores manuais estáticos.

A opção por uma arquitetura originalmente desenvolvida para ECG, em detrimento de modelos especializados em EEG como *EEGNet* (Lawhern et al., 2018) ou *DeepConvNet* (Schirrmeyer et al., 2017), fundamenta-se em três premissas metodológicas. Primeiro, a investigação da *hipótese de transferibilidade de domínio* entre bio-sinais não estacionários constitui, por si só, uma contribuição científica relevante, testando a universalidade de arquiteturas híbridas CNN-LSTM. Segundo, a RHCB5 apresenta documentação técnica completa e reproduzível, com hiperparâmetros explicitamente relatados, atributo crítico identificado como deficiente em diversos trabalhos da área. Terceiro, a escolha evita o viés de confirmação inerente ao uso de modelos já otimizados para o domínio-alvo, permitindo uma avaliação mais conservadora da capacidade de generalização da abordagem *end-to-end*. Arquiteturas especializadas em EEG permanecem como objeto de investigação prioritária para extensões futuras deste trabalho.

Como expoente desta categoria para o presente estudo, selecionou-se a Rede Híbrida Convolutacional Bidirecional (RHCB5), proposta por Maggioni e Rebonatto (2023, 2024). Embora originalmente validada para a detecção de arritmias em eletrocardiogramas (ECG), sua topologia (CNN-BiLSTM) é perfeitamente transponível para a análise de EEG, dada a similaridade na natureza estocástica e não estacionária de ambos os bio-sinais. A adoção da RHCB5 investiga, portanto, a hipótese de transferibilidade de domínio de arquiteturas profundas entre diferentes modalidades fisiológicas, juntamente com uma análise a respeito da interpretabilidade.

3.4.3 Síntese das Abordagens

As duas metodologias representam filosofias antagônicas para resolver o mesmo problema. A abordagem em *pipeline* decompõe o problema em etapas discretas, cada uma otimizada separadamente, enquanto a abordagem *end-to-end* busca uma solução holística e integrada. A Tabela 1 resume os principais compromissos e características de cada paradigma.

As etapas específicas e os métodos utilizados podem variar dependendo da aplicação, dos dados disponíveis e dos objetivos da análise. A abordagem em *pipeline* oferece transparência e a possibilidade de incorporar conhecimento especializado, ao custo de um maior esforço de desenvolvimento manual. Em contrapartida, a abordagem *end-to-end* oferece um alto grau de automação e o potencial para descobrir características originais, ao custo da interpretabilidade.

Apesar da vasta produção acadêmica, nota-se uma lacuna crítica de estudos que confrontem essas estratégias sob condições experimentais estritamente controladas. A maioria dos trabalhos foca na maximização de métricas isoladas, negligenciando a análise pareada com controle de aleatoriedade, essencial para dissociar a variância estocástica do desempenho intrínseco dos algoritmos. Este trabalho visa preencher essa lacuna, avaliando não apenas a acurácia, mas a robustez e a confiabilidade clínica de cada filosofia.

4 Materiais e Métodos

Esta seção descreve os recursos computacionais, o conjunto de dados e o desenho experimental empregados para a comparação direta entre duas abordagens de classificação de EEG. O desenho experimental visa uma comparação direta e pareada entre a abordagem em *pipeline* (BDA-KNN-DNN) e a abordagem *end-to-end* (RHCB5), conforme estabelecido na Seção 3. O experimento foi projetado para garantir a reprodutibilidade e a robustez estatística, utilizando um delineamento experimental pareado (*paired design*). O fluxo experimental compreende 30 repetições independentes para cada abordagem. O pilar central da validação é a técnica de Sementes Aleatórias Comuns (*Common Random Numbers - CRN*): em cada iteração i , gera-se uma semente única compartilhada por ambos os modelos (Subasi, 2019; Goodfellow et al., 2016). Esse procedimento assegura que a estratificação dos dados (treino, validação e teste) e a inicialização de parâmetros estocásticos sejam idênticas, permitindo a aplicação de testes estatísticos pareados e eliminando vieses de amostragem. O fluxo geral é ilustrado na Figura 3.

4.1 Materiais

Nesta etapa, são apresentados os recursos fundamentais utilizados para o desenvolvimento e validação das estratégias computacionais propostas. A descrição abrange o ecossistema de *software* e a base de dados de EEG selecionada, detalhando suas características e a definição das classes para o problema de detecção de epilepsia.

4.1.1 Ambiente de Software e Hardware

A implementação foi realizada na linguagem Python, escolhida por sua predominância na ciência de dados e pelo vasto ecossistema de bibliotecas de aprendizado profundo (Roy et al., 2019; Shoeibi et al., 2021). Para a construção, trei-

Tabela 1: Comparação entre abordagem *pipeline* e *end-to-end*.

Característica	Pipeline	End-to-End
Extração de Atributos	Manual, baseada em conhecimento de domínio (e.g., SWT, estatística).	Automática, aprendida a partir dos dados (e.g., camadas convolucionais).
Seleção de Atributos	Explícita, otimizada por meta-heurísticas (e.g., BDA).	Implícita, integrada ao aprendizado da rede.
Classificador	Opera em espaço de atributos de baixa dimensão e semanticamente rico.	Opera em representações latentes de alta dimensão e abstratas.
Interpretabilidade	Alta. O subconjunto de atributos pode gerar insights clínicos.	Baixa (“caixa-preta”). Difícil rastrear e explicar decisões.
Dependência de Domínio	Alta. Requer expertise para engenharia de atributos.	Baixa. Reduz a necessidade de engenharia manual.
Automação do <i>Pipeline</i>	Baixa. Múltiplas etapas de design e otimização.	Alta. Um único modelo aprende todas as etapas conjuntamente.
Custo Computacional (Inferência)	Geralmente baixo, pois o modelo final opera com poucos atributos.	Potencialmente alto, dependendo da arquitetura.
Custo Computacional (Desenvolvimento)	Alto, devido ao processo iterativo da seleção de atributos.	Alto, devido ao uso de grandes volumes de dados e longos treinamentos.




Figura 3: Fluxograma do desenho experimental pareado. Cada uma das 30 repetições compartilha a mesma semente aleatória (*seed*) entre ambas as abordagens.

namento e avaliação das Redes Neurais (tanto a DNN do *pipeline* quanto a RHCB5), utilizou-se o *framework* **TensorFlow** e sua interface de alto nível **Keras**.

A manipulação de dados e operações matriciais foram realizadas através das bibliotecas **Pandas** e **NumPy**. O pré-processamento e a análise estatística contaram com o auxílio do **SciPy** (para filtragem digital) e do **Scikit-learn**, este último utilizado para a divisão estratificada dos dados, cálculo de métricas de desempenho e implementação do classificador KNN na etapa de otimização.

A extração de características no domínio tempo-frequência foi realizada via **PyWavelets**. Para a visualização dos resultados e análise exploratória, empregaram-se as bibliotecas **Matplotlib** e **Seaborn**. Por fim, técnicas de Inteligência Artificial Explicável (XAI) foram aplicadas utilizando a biblioteca **SHAP**¹.

Os experimentos foram executados em uma estação de trabalho de alto desempenho, equipada com processador AMD Ryzen™ 5 5600X, 32 GB de memória RAM e aceleração de *hardware* via GPU NVIDIA GeForce RTX 3070 (arquitetura CUDA).

4.1.2 Conjunto de Dados

O estudo utiliza o *dataset* de EEG do Departamento de Epileptologia da Universidade de Bonn ([Arbeitsgruppen AG Lehnertz Neurophysik, Epileptologie, Universitätsklinikum Bonn, 2001](#)), amplamente reconhecido como referência para a validação de algoritmos de detecção de epilepsia. Os dados foram originados de registros contínuos multicanais de cinco voluntários saudáveis e cinco pacientes diagnosticados com epilepsia do lobo temporal.

O sistema de aquisição utilizou amplificadores de 128 canais, convertidos via conversor analógico-digital de 12 bits a uma taxa de amostragem de 173,61 Hz. Cada segmento temporal possui 23,6 segundos de duração, correspondendo a $N = 4096$ amostras após o pré-processamento inicial (o *data-*

¹<https://shap.readthedocs.io>

set original disponibiliza segmentos com 4097 pontos, sendo a última amostra descartada para compatibilidade com algoritmos de decomposição que exigem potências de dois). Seguindo a metodologia de [Yogarajan et al. \(2023\)](#), utilizam-se 300 segmentos distribuídos de forma balanceada (100 de cada) dos subconjuntos **A**, referente ao EEG de superfície em vigília com olhos abertos; **D**, consistindo em EEG intracraniano interictal da zona epileptogênica; e **E**, que compreende atividade ictal (convulsiva) de alta amplitude.

Embora a classificação da ILAE ([Beniczky, 2025](#)) ofereça uma categorização abrangente, é imperativo ressaltar que a validação experimental deste estudo emprega a base de dados de Bonn, cujos registros restringem-se historicamente a pacientes diagnosticados com epilepsia do lobo temporal. Consequentemente, as inferências apresentadas neste trabalho aplicam-se predominantemente ao contexto de epilepsias de início focal. A generalização dos resultados para crises de início generalizado ou desconhecido deve ser considerada com cautela teórica, visto que as morfologias e a dinâmica de propagação dessas etiologias diferem substancialmente dos padrões focais presentes nos dados utilizados.

4.2 Métodos

O procedimento metodológico, replicado em cada uma das 30 iterações, divide-se em pré-processamento, divisão de dados e execução dos fluxos específicos de cada abordagem.

4.2.1 Pré-processamento e Divisão dos Dados

Para garantir equidade na comparação, ambos os modelos recebem dados submetidos ao mesmo pré-processamento. Primeiro, ajusta-se o sinal, removendo a última amostra para reduzir os segmentos de 4097 para 4096 pontos, o que facilita decomposições que exigem potências de dois. Em seguida, aplica-se um filtro Butterworth passa-baixas de quarta ordem, com frequência de corte em 40 Hz, para atenuar ruídos de alta frequência e artefatos musculares ([Sanei e Chambers, 2007](#); [Subasi, 2019](#); [Yogarajan et al., 2023](#)). Esta decisão metodológica, embora sacrifique a informação das bandas Gamma (> 30 Hz) e HFOs — biomarcadores modernos da zona epileptogênica —, fundamenta-se em limitações do *data-set* histórico utilizado. Considerando a taxa de amostragem de 173,61 Hz, o **limite teórico de Nyquist** ([Sanei e Chambers, 2007](#)) situa-se em $\approx 86,8$ Hz. Na prática, a proximidade com a frequência da rede elétrica europeia (50 Hz) e a prevalência de artefatos musculares de amplo espectro degradam severamente a relação sinal-ruído nesta faixa. Optou-se, portanto, por um corte conservador em 40 Hz para garantir a pureza espectral nas bandas clássicas (Delta a Beta), onde reside a maior parte da energia das crises do lobo temporal, evitando o uso de filtros que poderiam introduzir distorções de fase não lineares e seguindo a implementação de [Yogarajan et al. \(2023\)](#) ([Sanei e Chambers, 2007](#); [Islam et al., 2018](#)).

Para preservar a integridade temporal do sinal, utiliza-se filtragem bidirecional (*zero-phase filtering* via função `filtfilt`), que processa a série em duas passagens (direta e reversa). Essa abordagem elimina deslocamentos de fase, preservando a localização temporal dos picos e a morfologia das descargas epileptiformes, aspectos essenciais para a extração de características e a classificação subsequente.

Por fim, os sinais passam por Padronização por Instância (*Instance Standardization*), em que cada segmento é ajustado

para ter média zero e desvio padrão unitário, garantindo estabilidade numérica no treinamento das redes neurais ([Islam et al., 2018](#); [Yogarajan et al., 2023](#)). Essa escolha visa mitigar a não estacionariedade dos sinais neurofisiológicos e evitar vazamento de dados (*data leakage*). Experimentos preliminares mostraram que normalizações globais, como *Min-Max Scaling* ou *Standard Scaler* (ajustados sobre todo o conjunto de treino), geram alta instabilidade na convergência das redes neurais em ambas as abordagens, por serem sensíveis a *outliers* e a variações absolutas de amplitude entre pacientes ou sessões, que nem sempre se relacionam à patologia. Ao normalizar localmente cada segmento, o modelo é forçado a aprender padrões morfológicos relativos e dinâmicos, em vez de se apoiar em amplitudes absolutas influenciadas pela impedância dos eletrodos ou por diferenças anatômicas individuais. Após esse tratamento, o conjunto de 300 segmentos é particionado de forma estratificada. Destinam-se 70% dos dados (210 segmentos) para o treinamento, 15% (45 segmentos) para a validação durante as épocas de aprendizado e os 15% restantes (45 segmentos) constituem o conjunto de teste, utilizado exclusivamente para a avaliação final das métricas.

4.2.2 Fluxo A: Pipeline BDA-KNN-DNN

Este fluxo adotou uma arquitetura modular clássica baseada na proposta de [Yogarajan et al. \(2023\)](#), porém adaptada para otimização computacional. Inicialmente, a etapa de **Extração de Características** utiliza a SWT para decompor o sinal, gerando um vetor de atributos por segmento. Subsequentemente, na fase de **Seleção de Características**, aplica-se o BDA sobre o conjunto de treinamento. O objetivo desta etapa é identificar um subconjunto reduzido de atributos que maximize a separabilidade das classes. Para tal, emprega-se uma estratégia *wrapper* onde um classificador KNN atua como função de avaliação (*fitness function*) para guiar a busca meta-heurística, estimando a qualidade dos subconjuntos sem o custo proibitivo de treinar uma rede neural a cada iteração. Por fim, o subconjunto de atributos considerado ótimo pelo avaliador KNN alimenta a etapa de **Classificação Final**, executada por uma DNN configurada para distinguir as três classes alvo com maior capacidade de generalização.

O detalhamento visual deste fluxo, explicitando a interação entre o otimizador e o classificador, encontra-se ilustrado no **Apêndice A** ([Figura 7](#)).

4.2.3 Fluxo B: Abordagem RHCB5

O segundo fluxo emprega a arquitetura *end-to-end* RHCB5 ([Maggioni e Rebonatto, 2024](#)), que processa o sinal bruto sem a necessidade de extração prévia de características manuais. A arquitetura é composta por um bloco inicial de Redes Neurais Convolucionais (1D-CNNs) responsáveis pela extração automática de mapas de características morfológicas locais. A sequência de características extraída é então processada por camadas de Memória de Longo Curto Prazo Bidirecional (Bi-LSTM), projetadas para modelar dependências temporais de longo prazo no sinal. A classificação final é realizada por camadas densas (*fully connected*). Diferente da abordagem original aplicada a ECGs, este estudo adapta a entrada da rede para acomodar a resolução temporal e espectral específica dos sinais de EEG.

A topologia completa da rede, detalhando a disposição das camadas de extração morfológica e modelagem temporal, é apresentada no **Apêndice A** ([Figura 8](#)).

4.3 Avaliação e Análise Estatística

A avaliação de desempenho baseia-se nas predições realizadas sobre o conjunto de teste. São calculadas métricas globais, como Acurácia, e métricas específicas por classe, incluindo Precisão, Sensibilidade (*Recall*), F1-Score e Especificidade.

Para validar estatisticamente a comparação, aplica-se um desenho experimental baseado na técnica de Sementes Aleatórias Comuns. Neste método, a i -ésima execução do *pipeline* BDA utiliza exatamente a mesma semente aleatória (*seed*) — e, consequentemente, a mesma estratificação de dados de treino/teste — que a i -ésima execução do RHCB5. Esta abordagem garante que ambos os modelos sejam avaliados sob condições idênticas em cada iteração, reduzindo a variância residual atribuída à amostragem dos dados e isolando o desempenho do algoritmo como fator principal. Devido a essa dependência estrutural entre as amostras, utiliza-se a análise estatística pareada. A normalidade das diferenças ($D_i = \text{Acc}_{\text{RHCB5},i} - \text{Acc}_{\text{BDA},i}$) é verificada pelo teste de Shapiro-Wilk. Caso a distribuição seja normal, aplica-se o Teste T Pareado; caso contrário, utiliza-se o Teste de Postos com Sinais de Wilcoxon, adotando-se $\alpha = 0.05$, padrão para estudos biomédicos que balanceia rigor estatístico e viabilidade amostral (Goodfellow et al., 2016).

5 Implementação e análise de resultados

Esta seção detalha os parâmetros específicos das arquiteturas implementadas e discute os resultados obtidos, confrontando as métricas quantitativas com aspectos de estabilidade, custo computacional e relevância clínica.

5.1 Implementação do BDA-KNN-DNN

A implementação deste fluxo observa uma arquitetura modular usada por Yogarajan et al. (2023), estruturada sequencialmente em três etapas fundamentais: extração, seleção otimizada e classificação final. Inicialmente, a etapa de Extração de Características fundamentou-se na metodologia de Yogarajan et al. (2023), empregando a SWT com a *wavelet* db4 em quatro níveis de decomposição. Este processo gerou 16 sub-bandas de frequência, a partir das quais foram calculados atributos estatísticos (como Valor Médio Absoluto, Desvio Padrão e Entropia) e razões de amplitude (*MAVsRatio*), resultando na conversão do sinal temporal em um vetor denso de 143 atributos por segmento (7 descritores estatísticos extraídos de cada uma das 16 sub-bandas, acrescidos de 31 razões de amplitude inter-bandas).

Na etapa subsequente, a fase de Seleção de Características empregou o BDA para a redução de dimensionalidade. Observou-se que a parametrização direta baseada em Yogarajan et al. (2023) — população de 10 agentes e 100 iterações — mostrou-se insuficiente para garantir a convergência adequada no ambiente experimental replicado, tendendo à estagnação em ótimos locais. Diante da ausência de detalhamento explícito sobre mecanismos auxiliares de exploração na obra de referência, o método foi reconstruído com base nos princípios fundamentais descritos por Mirjalili e Hashim (2016). Essa calibração da implementação incluiu o ajuste fino da inércia e a introdução de operadores de mutação estocástica, adaptações essenciais para assegurar a diversidade populacional e a eficácia da busca no espaço de atributos.

Esta experiência evidencia a importância crítica da documentação completa de hiperparâmetros para a reprodutibilidade científica.

A função de aptidão (*fitness*) utilizou um classificador KNN sob uma abordagem *wrapper* e validação cruzada de 10 *folds*, evitando o custo proibitivo do treinamento repetido de redes neurais. Dada a omissão de hiperparâmetros no estudo base (Yogarajan et al., 2023), realizou-se uma otimização extensiva (*grid-search*), definindo-se $k = 5$ e a distância de Manhattan como a configuração ideal para evitar enviesamentos. Embora essa validação garanta robustez, ela introduz um gargalo computacional de ordem $O(N \times T)$, mitigado neste trabalho via processamento paralelo. Ressalva-se, contudo, que em bases massivas ou cenários de monitoramento contínuo, a viabilidade exigiria a adoção de substitutos mais eficientes, como filtros ou modelos lineares.

Por fim, para a tarefa de classificação multiclasse (Normal, Interictal e Ictal), o subconjunto de atributos identificado como ótimo alimentou o Classificador Final (DNN). A rede, estruturada como um Perceptron Multicamadas, compõe-se de três camadas ocultas densas com 10 neurônios cada (cada um representando uma das classes do conjunto de Bonn), utilizando Normalização em Lote (*Batch Normalization*), função de ativação sigmoide e *Dropout* (0.1) para regularização. O treinamento, estendido por até 250 épocas, foi conduzido com o otimizador Adam e monitorado por *Early Stopping* (paciência de 30 épocas) para prevenir o sobreajuste.

A síntese entre a implementação do material base e as modificações inferidas permitiu a convergência do algoritmo, resultando em uma redução média de aproximadamente 65–66% do espaço de características (média de 49,2 atributos selecionados de 143). Entretanto, observou-se variabilidade significativa, o que sugere uma dificuldade do BDA em convergir para um subconjunto canônico único, demonstrando forte adaptação às especificidades de cada partição de treino.

5.2 Implementação da RHCB5

A adaptação da arquitetura RHCB5 para o domínio da epilepsia exigiu, preliminarmente, modificações substanciais no pré-processamento e na definição da camada de entrada, ajustada de 2.400 para 4.096 amostras. Divergindo das técnicas originais voltadas à fisiologia cardíaca — como filtros *Notch*, suavização LOESS e correção de *offset* —, optou-se por um filtro Butterworth passa-baixas com corte em 40 Hz e pela padronização estatística (*Z-Score*) por instância. Essa decisão metodológica fundamenta-se na natureza espectral do EEG, onde a eliminação de frequências superiores a 40 Hz remove artefatos musculares, enquanto a centralização dos dados otimiza a convergência da rede, tornando dispensável o oneroso processamento via LOESS.

Quanto à arquitetura, manteve-se estrita fidelidade à topologia original, concebida para operar de ponta a ponta (*end-to-end*). O fluxo de processamento inicia-se com quatro blocos convolucionais sequenciais, configurados com número decrescente de filtros (512, 256, 256 e 128) e *kernels* de tamanho 3. Estes blocos, intercalados por camadas de *Max Pooling* e *Dropout* (0.2), são responsáveis pela extração automática de padrões morfológicos locais. Subsequentemente, os mapas de características resultantes alimentam uma camada de Memória de Longo Curto Prazo Bidirecional (Bi-LSTM) com 256 unidades, projetada para modelar as dependências

Tabela 2: Comparação estatística detalhada: BDA-DNN vs RHCB5 (30 repetições). Métricas de desempenho apresentam Média $\pm$ Desvio Padrão. Tempos apresentam Mediana (Intervalo Interquartil). Δ refere-se à variação relativa.

Métrica	BDA-DNN	RHCB5	Δ (%)	p-value
Métricas Globais				
Acurácia	0.9037 $\pm$ 0.0366	0.9319 $\pm$ 0.0433	+3.12	0.0053
F1 Macro	0.9018 $\pm$ 0.0382	0.9314 $\pm$ 0.0435	+3.28	0.0043
Tempo Exec. (s)	58.50 (IQR 3.97)	37.83 (IQR 10.58)	-35.33	-
Tempo Treinamento (s)	29.96 (IQR 1.91)	34.10 (IQR 11.97)	+13.82	-
Classe Interictal (D)				
Recall	0.8000 $\pm$ 0.1021	0.9511 $\pm$ 0.0493	+18.89	-
Especificidade	0.9622 $\pm$ 0.0358	0.9522 $\pm$ 0.0516	-1.04	-
Precisão	0.9199 $\pm$ 0.0724	0.9164 $\pm$ 0.0830	-0.38	-
F1	0.8508 $\pm$ 0.0658	0.9310 $\pm$ 0.0517	+9.43	-
Classe Ictal (E)				
Recall	0.9822 $\pm$ 0.0347	0.8822 $\pm$ 0.0954	-10.18	0.0001
Especificidade	0.9422 $\pm$ 0.0463	0.9800 $\pm$ 0.0257	+4.01	0.0005
Precisão	0.9011 $\pm$ 0.0717	0.9589 $\pm$ 0.0497	+6.41	-
F1	0.9378 $\pm$ 0.0394	0.9159 $\pm$ 0.0592	-2.34	0.1138 (NS)

Testes Estatísticos: Teste T Pareado (Métricas Globais, Espec. E) e Wilcoxon (Recall E). Métricas da Classe Normal (A) foram omitidas por apresentarem desempenho equivalente entre ambas as abordagens. NS: Não Significativo.

temporais de longo prazo. O *pipeline* encerra-se com blocos densos de 256 e 128 neurônios, culminando em uma camada *softmax* para a classificação final.

No que tange ao regime de treinamento, o protocolo estático original de 60 épocas foi substituído por uma estratégia dinâmica com teto de 100 épocas e tamanho de lote (*batch size*) de 32. Para garantir a robustez do modelo, implementou-se o monitoramento via *Early Stopping* (paciência de 15 épocas) associado ao mecanismo de *checkpointing* com restauração de pesos ótimos (*restore best weights*). Esta abordagem revelou-se crítica para mitigar o *overfitting* tardio e descartar iterações prejudicadas por ruídos no treinamento, favorecendo uma generalização superior diante da alta variabilidade intersujeito inerente aos sinais cerebrais.

5.3 Análise de Resultados

A análise baseia-se nos dados agregados das 30 repetições independentes e pareadas. A Tabela 2 apresenta o resumo estatístico das principais métricas, expondo uma divergência significativa de desempenho e confiabilidade entre as abordagens.

A análise dos dados revela uma *trade-off* operacional claro, porém com implicações clínicas distintas. A abordagem **RHCB5** apresentou superioridade estatisticamente significativa ($p < 0.01$) nas métricas globais de Acurácia e F1-Score. Embora o BDA-DNN tenha obtido um desempenho excepcional na sensibilidade (*Recall*) da classe Ictal (**98,22% vs. 88,22%**), essa vantagem foi neutralizada por uma taxa crítica de erro na classe Interictal. O BDA apresentou desempenho inferior na discriminação deste estado (*Recall* de **80,00%**), gerando uma taxa de erro combinada de 20%, onde pacientes em estado interictal foram frequentemente confundidos com normais (9,6%) ou falsamente alarmados como em crise (10,4%). A RHCB5, por sua vez, resolveu este gargalo, elevando a detecção do difícil estado Interictal para **95,11%**. Isso indica que a extração automática de características via CNN/LSTM capturou as sutilezas morfológicas das descargas interictais que as estatísticas de *Wavelet* selecionadas pelo BDA não conseguiram isolar de forma robusta.

É imperativo ressaltar que os resultados obtidos refletem

um cenário experimental controlado. O *dataset* de Bonn ([Arbeitsgruppen AG Lehnertz Neurophysik, Epileptologie, Universitätsklinikum Bonn, 2001](#)), apesar de ser um padrão de referência na literatura, é composto por segmentos pré-selecionados e livres de artefatos significativos, o que não representa a complexidade ruidosa e contínua de um ambiente clínico real. A transição de dados segmentados para o monitoramento contínuo introduz desafios adicionais, como a necessidade de rejeição de artefatos em tempo real e o tratamento do desbalanceamento severo de classes, visto que eventos ictais são raros em registros de longa duração. Portanto, a generalização dos modelos aqui avaliados para dados ambulatoriais brutos deve ser considerada com cautela.

5.3.1 Eficiência, Estabilidade e Viabilidade Clínica

A avaliação da eficiência computacional revela uma dicotomia entre o tempo de desenvolvimento e o custo de inferência. Embora as médias de tempo total de execução sejam próximas (62s para o BDA *versus* 64s para a RHCB5), a análise da mediana expõe a latência introduzida pelo processo iterativo da meta-heurística: a RHCB5 registrou uma mediana de execução significativamente inferior (37,82s) comparada ao *pipeline* do BDA (58,49s). Sob a ótica de implementação em *hardware*, contudo, o modelo final gerado pelo BDA (uma MLP simples) apresenta vantagem em termos de FLOPS (operações de ponto flutuante por segundo) e consumo de memória para dispositivos embarcados, contrastando com a demanda de processamento das camadas convolucionais e recorrentes da RHCB5. Todavia, neste domínio de aplicação, a segurança clínica na distinção de estados prevalece sobre a economia marginal de recursos de inferência.

No que tange à estabilidade do desempenho, observa-se um fenômeno paradoxal no BDA-KNN-DNN: o modelo apresenta consistência na métrica final (DP $\approx$ 0,037, acurácia mínima de 82,22%), mas extrema volatilidade nos componentes internos. A RHCB5, em contrapartida, manteve-se robusta em patamares superiores (DP $\approx$ 0,043), com 75% das repetições ultrapassando 90% de acurácia global. Uma análise detalhada da frequência de seleção de atributos sugere que a eficácia do BDA apresenta instabilidade estocástica ([Guyon e Elisseeff, 2003](#)), dependendo da identificação

de subconjuntos estatísticos otimizados especificamente para cada partição de treinamento, um risco inerente a métodos *wrapper* (Guyon e Elisseeff, 2003), enquanto a abordagem *end-to-end* demonstra uma convergência sistêmica e generalizável.

A análise clínica aprofundada baseada nas matrizes de confusão (Figura 4) elucida a gravidade dos perfis de erro. O BDA-KNN-DNN atua como um detector de alta sensibili-

equipe médica à “fadiga de alarme” (*alarm fatigue*²), fenômeno que leva à dessensibilização e eventual ignorância dos avisos do equipamento. Por outro lado, a RHCB5 demonstra robustez operacional superior, com uma redução drástica da confusão Interictal → Ictal (apenas 3,1%). Esta mitigação do erro tipo I em estados interictais constitui uma contribuição clínica relevante, pois demonstra que a rede híbrida oferece um balanço entre sensibilidade e confiabilidade essencial para a segurança do paciente, viabilizando o uso da ferramenta em cenários de triagem automática, onde o excesso de falsos positivos inviabilizaria a operação.

5.3.2 Validação Estatística

A validade dos resultados foi assegurada pelo protocolo de Sementes Aleatórias Comuns (CRN). O teste de normalidade de Shapiro-Wilk indicou que as diferenças de acurácia seguiram uma distribuição normal ($W = 0.955, p = 0.241$), legitimando o uso do **Teste T Pareado**, que confirmou a diferença significativa ($p = 0.0053$) com tamanho de efeito médio.

Entretanto, a análise da frequência de seleção de atributos revela um problema de robustez na abordagem via pipeline. Ao contrário do esperado para um algoritmo de seleção eficaz, o BDA não convergiu para um subconjunto canônico de biomarcadores, apresentando uma distribuição de frequências quase uniforme e sem nenhuma característica selecionada em mais de 60% das execuções. A alta variabilidade no tamanho dos subconjuntos selecionados (média de 49 ± 30 atributos, ou seja, coeficiente de variação de 61%) implica que, entre as 30 execuções, o BDA apresentou alta variabilidade, selecionando desde 19 até 79 atributos, corroborando o fenômeno de instabilidade na seleção de características, frequentemente reportado na literatura de métodos *wrapper*. Conforme discutido por Dash e Liu (1997); Acharya, Sree, Swapna, Martis e Suri (2013); Guyon e Elisseeff (2003), essa flutuação indica que a meta-heurística priorizou o ajuste a correlações estatísticas locais e ruídos específicos de cada partição (*overfitting*), em detrimento da identificação de biomarcadores fisiológicos estáveis. Este comportamento estocástico golpeia o principal argumento em favor dos *pipelines* de seleção: a suposta interpretabilidade. A “caixa branca” revela-se, portanto, instável e dependente da sorte da inicialização, contrastando com a consistência de representação aprendida pela abordagem *end-to-end*.

5.3.3 Interpretabilidade

Para elucidar os mecanismos de decisão, aplicaram-se técnicas de Inteligência Artificial Explicável (*Explainable Artificial Intelligence - XAI*) aos melhores modelos de cada abordagem, respeitando suas restrições arquitetônicas. O SHAP (*SHapley Additive exPlanations*), agnóstico ao modelo, quantifica a contribuição de qualquer entrada (atributo tabular ou ponto no sinal temporal) (Lundberg e Lee, 2017). Já o Grad-CAM (*Gradient-weighted Class Activation Mapping*) exige camadas convolucionais que preservem a estrutura espacial ou temporal para gerar mapas de calor (Selvaraju et al., 2017). Por isso, foi aplicado apenas à RHCB5, cuja arquitetura com camadas Conv1D mantém a dimensão temporal e permite localizar padrões morfológicos. No *pipeline* BDA-KNN-DNN, o Grad-CAM é inviável, pois a SWT converte o




Figura 4: Matrizes de Confusão Agregadas das 30 repetições.

dade para picos de energia (crises), mas a um custo proibitivo de especificidade. A taxa de erro de 20% na classe Interictal — onde 10,4% dos segmentos basais foram classificados incorretamente como crise — inviabiliza sua aplicação em monitoramento contínuo. Em um cenário clínico, essa taxa geraria um volume massivo de falsos positivos, induzindo a

²<https://www.apsf.org/pt-br/article/fadiga-de-alarme-e-seguranca-do-paciente/>

sinal temporal em um vetor tabular de estatísticas agregadas (como média e entropia), eliminando a dimensão temporal necessária aos gradientes espaciais.

No âmbito do *pipeline* BDA-KNN-DNN, a análise da importância agregada das características via SHAP (Figura 5) aprofundou a avaliação da seleção de atributos. O algoritmo convergiu para um subconjunto médio de 49,2 atributos (de 143), resultando em uma redução de dimensionalidade de aproximadamente 65 – 66%. Esta taxa é inferior à redução de 85% reportada por Yogarajan et al. (2023), uma discrepância possivelmente atribuível à ausência de detalhamento rigoroso sobre os hiperparâmetros no trabalho original, o que dificultou a reprodução exata das condições de convergência.




Figura 5: Importância Agregada das *Features* no BDA-KNN-DNN (Top 30) via análise SHAP. O gráfico pondera a frequência de seleção pela acurácia obtida. Nota-se a predominância de atributos de baixa frequência (prefixo AAAA) no topo do ranking, em detrimento de biomarcadores canônicos de alta frequência.

A análise qualitativa do *ranking* de importância expõe não apenas um padrão contraditório em relação à fisiopatologia esperada, mas também uma falha estrutural de aprendizado. Embora a literatura médica estabeleça que as crises epiléticas são marcadas por descargas de alta energia e frequência (*spiking activity*) — e apesar de características associadas a estas bandas (e.g., DDDA, DADA) constarem na seleção —, observa-se uma predominância inesperada de componentes de baixa frequência nas posições de maior relevância. Esta liderança é exercida por atributos derivados dos coeficientes de aproximação, como AAAA_Complexity (selecionada em 12 das 30 execuções) e AADD_Skewness.

A priorização de componentes lentos sugere que o algoritmo pode estar capturando flutuações de linha de base (*baseline wander*) ou características instrumentais específicas do amplificador, em vez de isolar a atividade ictal genuína. Este comportamento, aliado à alta volatilidade na escolha dos atributos entre as repetições, corrobora a hipótese de que o modelo incorreu em *overfitting* estatístico. Ao invés de aprender a fenomenologia da doença — o que resultaria na seleção estável de biomarcadores canônicos —, o algoritmo limitou-se a reter ruídos e correlações espúrias específicas da partição de treinamento para minimizar a função de custo. O BDA operou, portanto, como um otimizador matemático eficiente, mas falhou em atuar como um descobridor de conhecimento clínico robusto, fragilizando sua aplicabilidade como ferramenta confiável de suporte à decisão em cenários não controlados.

Em contrapartida, na abordagem RHC5, optou-se pela aplicação do Grad-CAM (Figura 6) em detrimento do SHAP. Embora o SHAP seja agnóstico ao modelo, sua aplicação em sinais brutos de alta dimensionalidade tende a gerar explicações dispersas e computacionalmente custosas, muitas vezes difíceis de correlacionar com eventos morfológicos específicos no tempo. O Grad-CAM, ao explorar os mapas de ativação das camadas convolucionais, permite preservar a estrutura espacial e temporal dos dados, validando visualmente o aprendizado *end-to-end* e revelando estratégias de atenção análogas à inspeção clínica.




Figura 6: Análise de Grad-CAM na RHC5. (Linha 1 - Normal): Atenção difusa monitorando o ritmo de fundo. (Linha 2 - Interictal): Atenção focalizada em transientes e espículas, crucial para o diagnóstico correto. (Linha 3 - Ictal): Ativação intensa acompanhando a descarga energética.

Observa-se que, enquanto a classe Normal elicia uma ativação difusa para o monitoramento da estabilidade global, a classe Interictal provoca focos de atenção intensos e localizados. Especificamente na linha 2 (Interictal), nota-se que as regiões de cor vermelha (alta ativação) alinham-se temporalmente de forma precisa às espículas e transientes breves do sinal em cor azul. Essa discriminação, que requer morfologias sutis, justifica a superioridade de desempenho do mo-

delo em relação ao BDA. Por fim, a classe Ictal apresenta ativação massiva e contínua, rastreando fielmente a evolução energética da crise. Tais evidências confirmam que o modelo desenvolveu detectores de características robustos, operando por varredura na normalidade, foco em anomalias interictais e rastreamento de descargas sustentadas.

6 Considerações Finais

Este trabalho apresentou uma análise comparativa sistemática entre duas filosofias predominantes para a detecção de epilepsia em sinais de EEG: o *pipeline* clássico otimizado (BDA-KNN-DNN) e a abordagem de aprendizado profundo integrada (RHCB5). Através de repetições pareadas com controle de aleatoriedade, foi possível avaliar não apenas a acurácia máxima, mas também a estabilidade e a consistência de cada método.

Um aspecto crítico observado refere-se à reprodutibilidade da abordagem em *pipeline*. A implementação do BDA exigiu um esforço substancial de inferência técnica, visto que [Yogarajan et al. \(2023\)](#) apresentaram uma parametrização inviável na prática e omitiram configurações do classificador *wrapper* (KNN), forçando a adoção de premissas baseadas na literatura fundamental ([Mirjalili e Hashim, 2016](#)). Em contraste, a arquitetura RHCB5 ([Maggioni e Rebonatto, 2024](#)) demonstrou alta fidelidade de reprodução: sua descrição topológica clara permitiu a transposição direta do domínio original (ECG) para EEG com modificações mínimas. Essa facilidade, aliada à superioridade estatística comprovada, reforça a viabilidade da abordagem *end-to-end* como artefato científico metodologicamente mais reprodutível e acessível para adoção clínica.

Conclui-se que a escolha entre *pipeline* e *end-to-end* depende do contexto de aplicação. Cenários que exigem explicação clínica detalhada e ambientes com severas restrições de memória podem se beneficiar do BDA-KNN-DNN, desde que tolerem maior variância. Entretanto, para triagem massiva ou monitoramento contínuo, onde a segurança do paciente e a minimização de falsos negativos são prioritárias, a RHCB5 apresenta-se como uma solução mais segura e eficaz.

Como trabalhos futuros, propõe-se uma agenda estruturada em três eixos. **Primeiro**, validação ecológica em registros contínuos de longa duração (CHB-MIT³) mediante: (i) segmentação com janelas deslizantes e sobreposição; (ii) *data augmentation* via *jittering* temporal e adição de ruído gaussiano ($\sigma \leq 10\%$ RMS); (iii) balanceamento de classes via SMOTE temporal ou ponderação focal de perdas; e (iv) rejeição automática de artefatos por limiarização adaptativa e análise espectral. **Segundo**, refinamento metodológico: no *pipeline*, substituir o *wrapper* KNN ($O(N \times T)$) por filtragem via *Mutual Information* ($O(N \log N)$) e adotar classificadores XGBoost⁴ com interpretabilidade nativa; na RHCB5, integrar *Self-Attention* nas camadas convolucionais, *Temporal Attention* entre Bi-LSTM e camadas densas, e aplicar *Transfer Learning* com pré-treinamento no TUH EEG Corpus⁵ (> 60.000 registros de EEG). **Terceiro**, comparação direta com arquiteturas especializadas (EEGNet, DeepConvNet) sob o mesmo

protocolo pareado com CRN, validando definitivamente a hipótese de transferibilidade de domínio *versus* especialização arquitetural.

6.1 Contribuições deste estudo

Este trabalho oferece quatro contribuições principais à literatura: (1) a comparação direta e pareada entre paradigmas de *pipeline* e *end-to-end* para a detecção de epilepsia sob controle experimental rigoroso; (2) a demonstração empírica de que a superioridade de acurácia da RHCB5 se sustenta através da análise de estabilidade estocástica; (3) a identificação da redução crítica da confusão entre estados Interictais e Ictais pela arquitetura híbrida, possivelmente resolvendo um dos maiores gargalos para a aplicação clínica de sistemas automáticos; e (4) a evidência, via XAI, de que o BDA pode convergir para biomarcadores não canônicos em alta dimensionalidade.

6.2 Limitações e Ameaças à Validade

Embora o desenho experimental tenha sido rigoroso, algumas limitações devem ser reconhecidas. Primeiro, o *dataset* de Bonn, apesar de ser referência na literatura, consiste em segmentos pré-selecionados e limpos, não refletindo a complexidade de registros contínuos com artefatos. Segundo, a análise se restringe a epilepsias focais do lobo temporal; a generalização para crises generalizadas ou de início desconhecido requer validação adicional. Terceiro, o tamanho amostral de 300 segmentos, embora suficiente para análise comparativa, pode limitar a capacidade de capturar a variabilidade interpaciente. Por fim, no que tange especificamente à abordagem RHCB5, identifica-se como limitação atual a sua complexidade computacional para inferência em dispositivos de borda (*edge computing*) com restrições severas de energia, bem como a opacidade inerente às redes profundas, que, mesmo mitigada pelo Grad-CAM, não fornece uma lista explícita de regras de decisão como o *pipeline* baseado em atributos.

Referências

- Acharya, U. R., Hagiwara, Y., Deshpande, S. N., Suren, S., Koh, J. E. W., Oh, S. L., Arunkumar, N., Ciaccio, E. J. e Lim, C. M. (2021). Characterization of focal EEG signals: A review, *Sensors* **21**(24): 8485.
- Acharya, U. R., Sree, S. V., Swapna, G., Martis, R. J. e Suri, J. S. (2013). Automated eeg analysis of epilepsy: a review, *Knowledge-Based Systems* **45**: 147–165.
- Acharya, U. R., Sreeja, V. P., Swapna, G., Martis, R. J. e Suri, J. S. (2013). Automated diagnosis of epilepsy using different feature extraction techniques with artificial neural networks, *Knowledge-Based Systems* **45**: 147–155.
- Adam, A., Shapiai, M. I., Mohd Tumari, M. Z., Mohamad, M. S. e Mubin, M. (2014). Feature selection and classifier parameters estimation for EEG signals peak detection using particle swarm optimization, *The Scientific World Journal* **2014**: 1–13.

³<https://doi.org/10.13026/C2K01R>

⁴<https://xgboost.ai/about>

⁵https://isip.piconepress.com/projects/tuh_eeg/

- Adeli, H., Ghosh-Dastidar, S. e Dadmehr, N. (2003). Wavelet analysis of eeg for epilepsy detection, *Clinical Neurophysiology* **114**(5): 845–855.
- Al-Ghamdi, M. e Sheikh, M. (2024). A hybrid binary dragonfly algorithm with differential evolution for optimal eeg feature selection in epilepsy detection, *Neurocomputing* **560**: 126754.
- Arbeitsgruppen AG Lehnertz Neurophysik, Epileptologie, Universitätsklinikum Bonn (2001). Bonn eeg dataset, <https://www.ukbonn.de/epileptologie/arbeitsgruppen/ag-lehnertz-neurophysik/downloads/>. Acesso em: 10 maio 2025.
- Becerra-Rozas, M., Lemus-Romani, J., Cisternas-Caneo, F., Crawford, B., Soto, R., Astorga, G., Castro, C. e García, J. (2023). Continuous metaheuristics for binary optimization problems: An updated systematic literature review, *Mathematics* **11**(1).
URL: <https://www.mdpi.com/2227-7390/11/1/129>
- Beniczky, Eugen Trinka, e. a. (2025). Updated classification of epileptic seizures: Position paper of the international league against epilepsy, *Epilepsia* pp. 1–20.
- Chantar H., Tubishat M., E. M. e. a. (2021). Hybrid binary dragonfly algorithm with simulated annealing for feature selection, *SN Computer Science* **2**(4): 295.
- Cherukuvada, S. e Kayalvizhi, R. (2023). Feature selection with deep belief network for epileptic seizure detection on eeg signals, *Computers, Materials & Continua* **75**(2): 4101–4118.
URL: <http://www.techscience.com/cmc/v75n2/52082>
- Dash, M. e Liu, H. (1997). Feature selection for classification, *Intelligent Data Analysis* **1**(3): 131–156.
- Emary, E., Zawbaa, H. M. e Hassanien, A. E. (2016). Binary dragonfly algorithm for feature selection, *2016 11th International Conference on Computer Engineering & Systems (ICCES)*, pp. 114–119.
- Engel Jr., J., Moshé, S. L., Galanopoulou, A. S., Stern, J. M., Arzimanoglou, A., French, J. A., Guerrini, R., Kanner, A. M. e Mody, I. (eds) (2024). *Epilepsy: A Comprehensive Textbook*, 3rd edn, Wolters Kluwer, Philadelphia.
- Epilepsy Foundation (2025). What is epilepsy?, <https://www.epilepsy.com/what-is-epilepsy>. Accessed: May 6, 2025.
- Falach, R., Geva-Sagiv, M., Eliashiv, D., Goldstein, L., Budin, O., Gurevitch, G., Morris, G., Strauss, I., Globerson, A., Fahoum, F., Fried, I. e Nir, Y. (2024). Annotated interictal discharges in intracranial eeg sleep data and related machine learning detection scheme, *Scientific Data* **11**(1): 1354.
URL: <https://doi.org/10.1038/s41597-024-04187-y>
- Goodfellow, I., Bengio, Y. e Courville, A. (2016). *Deep learning*, MIT press.
- Guhdar, M., Mstafa, R. J. e Mohammed, A. O. (2025). Hybrid deep learning model for epileptic seizure classification by using 1d-cnn with multi-head attention mechanism.
URL: <https://arxiv.org/abs/2501.10342>
- Guyon, I. e Elisseeff, A. (2003). An introduction to variable and feature selection, *Journal of Machine Learning Research* **3**: 1157–1182.
URL: <http://jmlr.org/papers/v3/guyon03a.html>
- Hjorth, B. (1970). Eeg analysis based on time domain properties, *Electroencephalography and clinical neurophysiology* **29**(3): 306–310.
- Husain, A. M. (ed.) (2023). *Current Practice of Clinical Electroencephalography*, 5th edn, Wolters Kluwer.
- Islam, M. K., Rastegarnia, A. e Yang, Z. (2018). A review on the preprocessing techniques of electroencephalogram signals, *Neurocomputing* **318**: 23–35.
- Jasper, H. H. (1958). The ten-twenty electrode system of the international federation, *Electroencephalography and clinical neurophysiology. Supplement* **10**: 371–375.
- Kennedy, J. e Eberhart, R. (1997). A discrete binary version of the particle swarm algorithm, *Proceedings of the 1997 IEEE International Conference on Systems, Man, and Cybernetics. Computational Cybernetics and Simulation*, Vol. 5, pp. 4104–4108.
- Kennedy, J. e Eberhart, R. C. (1995). Particle swarm optimization, *Proceedings of ICNN'95-International Conference on Neural Networks*, Vol. 4, IEEE, pp. 1942–1948.
- Khan, A. I., Saad, N. M. e Ahmad, I. (2023). Epileptic seizure detection in eeg signals using a novel 1d-cnn and bidirectional lstm architecture, *IEEE Access* **11**: 134502–134515.
- Lawhern, V. J., Solon, A. J., Waytowich, N. R., Gordon, S. M., Hung, C. P. e Lance, B. J. (2018). Eegnet: a compact convolutional neural network for eeg-based brain-computer interfaces, *Journal of Neural Engineering* **15**(5): 056013.
- Li, Y., Wang, H., Zhang, Y., Li, X. e Chen, Y. (2024). PMP-PSO: An EEG feature optimization method for epilepsy detection based on improved particle swarm optimization algorithm, *Frontiers in Computational Neuroscience* **18**: 1416838.
- Lotte, F., Bougrain, L., Cichocki, A., Clerc, M., Congedo, M., Rakotomamonjy, A. e Yger, F. (2018). A review of classification algorithms for eeg-based brain-computer interfaces: a roadmap for beginners, *Journal of Neural Engineering* **15**(6): 062004.
- Lu, D. e Triesch, J. (2019). Residual deep convolutional neural network for eeg signal classification in epilepsy, *arXiv preprint arXiv:1903.08100*.
- Lundberg, S. M. e Lee, S.-I. (2017). A unified approach to interpreting model predictions, *Proceedings of the 31st International Conference on Neural Information Processing Systems, NIPS'17*, Curran Associates Inc., Red Hook, NY, USA, pp. 4768–4777.
- Mafarja, M. M. e Mirjalili, S. (2017). Binary dragonfly algorithm for discrete optimization problems, *International Journal of Thermal Sciences* **112**: 1–13.

- Maggioni, A. F. e Rebonatto, M. T. (2023). Inteligência Artificial aplicada a análise de Eletrocardiograma, *Salão de Iniciação Científica (SIC) - PF 2023*, Passo Fundo, RS, Brasil. Trabalho de Iniciação Científica.
- Maggioni, A. F. e Rebonatto, M. T. (2024). DETECÇÃO DE ARRITMIAS CARDÍACAS: ABORDAGEM DA DERIVAÇÃO I COM REDES NEURAIIS HÍBRIDAS, *Revista interfaces* **12**(4): 4585–4600.
- Martínez-Vargas, M. E., Gutiérrez-Osorio, G., Almanza-Ojeda, D. L. e Román-Godínez, I. (2022). Evaluation of feature selection methods for classification of epileptic seizure EEG signals, *Applied Sciences* **12**(8): 3997.
- Mirjalili, S. e Hashim, S. Z. (2016). Dragonfly algorithm: a new meta-heuristic optimization technique for solving single-objective, discrete, and multi-objective problems, *Neural Computing and Applications* **27**(4): 1053–1073.
- Molina, L. C., Belanche, L. e Nebot, A. (2002). Feature selection algorithms: A survey and experimental evaluation, *Proceedings of the 2002 IEEE International Conference on Data Mining (ICDM 2002)*, pp. 306–313.
- Noachtar, S. e Beier, C. P. (2021). *Atlas of Epileptic Seizures and Syndromes*, 2nd edn, Springer, Cham.
- Pfurtscheller, G. e Lopes da Silva, F. H. (eds) (1999). *Handbook of Electroencephalography and Clinical Neurophysiology. Volume 1: Event-Related Desynchronization*, Vol. 1 of *Handbook of Electroencephalography and Clinical Neurophysiology*, Elsevier, Amsterdam.
- Pillai, J. e Sperling, M. R. (2007). Eeg artifacts, *Current opinion in neurology* **20**(2): 153–160.
- Qi, Y., Ding, F., Xu, F. e Yang, J. (2020). Channel and feature selection for a motor imagery-based bci system using multilevel particle swarm optimization, *Computational Intelligence and Neuroscience* **2020**(1): 8890477.
- Roy, Y., Banville, H., Albuquerque, I., Gramfort, A., Falk, T. H. e Faubert, J. (2019). Deep learning-based electroencephalography analysis: a systematic review, *Journal of neural engineering* **16**(5): 051001.
- Sanei, S. e Chambers, J. A. (2007). *EEG signal processing*, John Wiley & Sons.
- Schirrmeister, R. T., Springenberg, J. T., Fiederer, L. D. J., Glasstetter, M., Eggenberger, K., Tangermann, M., Hutter, F., Burgard, W. e Ball, T. (2017). Deep learning with convolutional neural networks for eeg decoding and visualization, *Human Brain Mapping* **38**(11): 5391–5420.
- Schomer, D. L. e Lopes da Silva, F. H. (eds) (2018). *Niedermeyer's Electroencephalography: Basic Principles, Clinical Applications, and Related Fields*, 7th edn, Oxford University Press, New York.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D. e Batra, D. (2017). Grad-cam: Visual explanations from deep networks via gradient-based localization, *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 618–626.
- Shoeibi, A., Khodatars, M., Ghassemi, N., Jafari et al. (2021). Epileptic seizures detection using deep learning techniques: A review, *International Journal of Environmental Research and Public Health* **18**(11): 5780.
- Sturm, I., Lapuschkin, S., Samek, W. e Müller, K.-R. (2016). Interpretable deep neural networks for single-trial eeg classification, *Journal of Neuroscience Methods* **274**: 141–145.
- Subasi, A. (2007). Feature selection by using genetic algorithm for diagnosis of parkinson's disease, *Applied Artificial Intelligence* **21**(9): 1033–1044.
- Subasi, A. (2010). Eeg signal classification using wavelet feature extraction and a mixture of expert model, *Expert systems with Applications* **37**(12): 1084–1093.
- Subasi, A. (2019). *Practical Guide for Biomedical Signals Analysis Using Machine Learning Techniques: A MATLAB Based Approach*, Academic Press, London; San Diego, CA; Cambridge, MA; Oxford.
- Teplan, M. (2002). Fundamentals of eeg measurement, *Technical report*, Slovak Academy of Sciences.
URL: <https://www.measurement.sk/2002/S2/Teplan.pdf>
- Wang, K., Liu, M. e Sun, H. (2024). Novel deep learning framework for detection of epileptic seizures using 1-d cnn-bilstm hybrid, *Frontiers in Computational Neuroscience* **18**: 1340251.
- Wang, R., Wang, H., Shi, L., Han, C. e Che, Y. (2022). Epileptic Seizure Detection Using Geometric Features Extracted from SODP Shape of EEG Signals and AsyLnCPSO-GA, *Entropy* **24**(11): 1540.
- Welch, P. D. (1967). The use of fast fourier transform for the estimation of power spectra: a method based on time averaging over short, modified periodograms, *IEEE Transactions on audio and electroacoustics* **15**(2): 70–73.
- Yogarajan, V., Ramakrishnan, S., Elavarasan, R. M., Saini, M., Bajaj, M., Shafi, J. e Khan, I. A. (2023). Eeg-based epileptic seizure detection using binary dragonfly algorithm and deep neural network, *Diagnostics* **13**(1): 283.
- Zhang, Y., Wang, Y., Zhou, L., Wang, J. e Zhang, J. (2024). A review of epilepsy detection and prediction methods based on EEG signal processing and deep learning, *Frontiers in Neuroscience* **18**: 1468967.

A Detalhamento das Arquiteturas Computacionais

Este apêndice apresenta as representações visuais detalhadas dos fluxos de processamento implementados para elucidar as diferenças estruturais entre a abordagem em *pipeline* e a abordagem *end-to-end*.

A.1 Fluxograma da Abordagem em Pipeline (BDA-KNN-DNN)

A Figura 7 ilustra o processo sequencial adotado no Fluxo A. Destaca-se o laço de realimentação na etapa de seleção de atributos, onde o algoritmo genético (BDA) utiliza um classificador KNN simplificado para guiar a busca pelo subconjunto ótimo de características, antes do treinamento final da rede neural profunda.





Figura 7: Fluxograma detalhado do método BDA-KNN-DNN. O processo inicia com a extração massiva de atributos via Wavelet, seguida por uma otimização iterativa *wrapper* e finalizada por uma rede neural classificadora.



h

Figura 8: Arquitetura da RHC5 adaptada para EEG. O modelo processa o sinal bruto de entrada (4096 amostras), extraindo hierarquicamente características espaciais e temporais até a decisão de classe.

A.2 Diagrama da Arquitetura *End-to-End* (RHC5)

A Figura 8 detalha a topologia da Rede Híbrida Convolutiva Bidirecional utilizada no Fluxo B. A imagem evidencia a transição do sinal bruto através de blocos convolucionais (cor laranja) para a extração de morfologias locais, seguidos pelo processamento sequencial bidirecional (cor verde) para a captura de dependências temporais, culminando na classificação densa (cor azul).